



# Machine Learning Deep Learning

GyeongYeong, Kim  
I-Eon, Na

# ML/DL Goal

PIAI Research Department

- Keras / Pytorch에 대한 전반적인 Framework에 이해한다.
- 이미지 데이터셋에 대한 분류를 딥러닝 네트워크로 학습할 수 있다.
- 자신이 학습한 모델에 대해 분석할 수 있다.
- 기존의 다른 모델을 가져와 적용할 수 있다.

# ML/DL Lab

PIAI Research Department

- 1일차 : Framework / Classifier(~DNN)
- 2일차 : Analysis Tools / Feature Extraction(~CNN)
- 3일차 : Additional Func.(Data Augmentation / Fine Tuning)

Customization

- 4일차 : Additional Func.(Data Augmentation / Fine Tuning)

RNN / GAN

# ML/DL Lab 1st Day

PIAI Research Department

- **Keras Basic**

- Framework Introduction
- $Y=3X$  Regression
- ANN/DNN with MNIST
- Model 저장,로드

- **Pytorch Basic**

- Framework Introduction
- $Y=3X$  Regression
- ANN/DNN with MNIST
- Model 저장,로드

# ML/DL Lab 2<sup>nd</sup> Day

PIAI Research Department

- Keras Model Analysis
  - Callback
  - History 확인
  - 틀린샘플 확인
  - Confusion Matrix
- Feature Extraction
  - CNN / Pooling Layer
  - Batch Normalization / DropOut
- Pytorch Feature Extraction
  - CNN / Pooling Layer
  - Batch Normalization / DropOut
  - Best Model Saving
  - History 확인
  - Confusion Matrix
  - 틀린샘플 확인
  - Early Stopping

# ML/DL Lab 3<sup>rd</sup> Day

PIAI Research Department

- **Keras Additional Functions**
  - CIFAR10 Introduction
  - Model Summation
  - Data Augmentation
  - Transfer Learning
- **Pytorch Additional Functions**
  - Data Augmentation
  - Transfer Learning
  - Training Customized Dataset(Man/Monkey)

# ML/DL Lab 4<sup>th</sup> Day

PIAI Research Department

- **Keras Additional Functions**

- **LSTM (with MNIST)**
- **GAN (with MNIST)**

- **Pytorch Additional Functions**

- **GAN (with MNIST)**
- **Quiz**

# ML/DL Lab Recommendation

PIAI Research Department

- **인트로 – 코딩 – 직접 실습**
- **이론과 다소 별개 : 구체적인 용어 특성이나 성질들은 이론 수업이나 검색으로 해결할 것**
- **Coding Time : 수업 시간내 잘 집중해서 진행할 것(수업 이후 정답지 제공)**
- **동작 관련 오류 : 각 반 보조에게 손들고 해결 요청**
- **숙제 : 혼자 힘으로 다양하게 시도해보면서 배워볼 것**
- **퀴즈 : 실습 수업 내용 잘 들으면서 공부할 것**

# ML/DL Homework

PIAI Research Department

- MNIST 데이터셋의 학습 / 평가 / 분석 (Keras / Pytorch 중 택1)
- 제출 파일 : 해당 파일이 들어있는 zip 파일 : ex) HW\_김경영.zip
  - Homework\_(이름).ipynb (모두 Run한 상태로)
  - 보고서\_(이름).docx
- 정확도(60%) - 진행 전략(20%) - 분석(20%)을 통합적으로 평가
  - 정확도 : 99.75% 넘으면 만점 (넘으면 굳이 더 학습해보려고 하진 않아도 됨)
  - 진행 전략 : Keras/Torch 라이브러리 내 적용할 수 있는 수준의 네트워크로 학습 (너름시도해본 Trial들을 간단하게 정리해도 좋음!)
  - 학습 분석 : Under/Over fitting 여부 확인 / 학습 안정화 여부 확인
  - 성능 분석 : 잘못된 분류 케이스 확인 / 개선할 수 있는 방향 제안 / 현실적인 최대 정확도 제안
- 제출 시 최저점수가 40점이므로 늦더라도 제출 할 것 (미제출 : 0점)
- 표절 심증이 있을 시, 최저점수 반영

# ML/DL Lab Quiz

PIAI Research Department

- **True/False : 6문제 (30)**
- **단답형 : 10문제 (30)**
- **실습 코드 : 2문제 (20)**
- **서술형 : 1문제 (20)**



# Keras Basic

GyeongYeong, Kim

# 딥러닝 프레임워크 Timeline

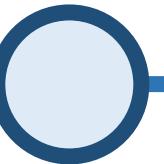
PIAI Research Department

2010



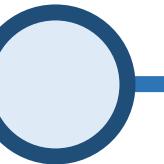
theano

2013

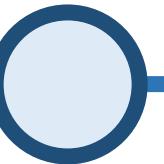


Caffe

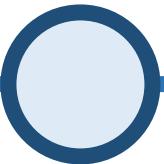
2014



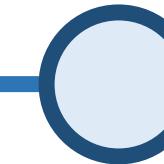
2015



2016



2017



# 딥러닝 프레임워크 비교

PIAI Research Department



주체	플랫폼	모바일	언어	인터페이스	OpenMP	Cuda	OPenCL	멀티GPU	분산
SkyMind	Cross-platform	Android	Java	Java, Scala, Python	Y	Y	-	Y	Y (Spark)

## 장점

- 가장 많은 프로그래머를 보유하는 Java 기반 딥러닝 프레임워크
- 쉬운 이식성, 높은 안정성
- 문서화가 잘되어 있음
- 시각화 도구 제공

## 단점

- Java의 언어적 특성으로 인해 학습 및 테스트 과정이 번거로움
- 협소한 사용자 커뮤니티
- 부족한 예제

# 딥러닝 프레임워크 비교

PIAI Research Department



주체	플랫폼	모바일	언어	인터페이스	OpenMP	Cuda	OPenCL	멀티GPU	분산
BAIR, facebook	Linux, Mac	-	C++	Python, C++	Y	Y	-	Y	-

## 장점

- 이미지 처리에 특화
- Caffe Model Zoo를 통한 다양한 Pre-trained Model 제공

## 단점

- 이미지 이외의 데이터 처리에는 부적합(텍스트, 사운드 등)
- 유연하지 못한 API(C++/CUDA로 직접 구현 필요)
- 문서화가 잘 안되어 있음

# 딥러닝 프레임워크 비교

PIAI Research Department



주체	플랫폼	모바일	언어	인터페이스	OpenMP	Cuda	OPenCL	멀티GPU	분산
Facebook	Linux, Mac, Window	Android, iOS	Lua	python	Y	Y	Y	Y	Y

## 장점

- 알고리즘 모듈화가 잘되어 있어 사용이 용이
- 다양한 데이터 전처리 및 시각화 유틸리티 제공
- 직관적인 API
- 다양한 Pre-trained Model 제공

## 단점

- Lua 언어 자체가 Java/Python보다 폐쇄적
- 상용 어플리케이션이 아니라 연구용으로 적합

# 딥러닝 프레임워크 비교

PIAI Research Department

## theano

주체	플랫폼	모바일	언어	인터페이스	OpenMP	Cuda	OPenCL	멀티GPU	분산
Google	Linux, Mac, Window	-	Python	Python	Y	Y	-	Y	-

### 장점

- Low-level을 제어할 수 있는 API
- 빠르고 유연함
- Wrapper 프레임워크의 기반 프레임워크(Keras)

### 단점

- 매우 복잡함
- 2017년 이후 공식 지원 마감

# 딥러닝 프레임워크 비교

PIAI Research Department



주체	플랫폼	모바일	언어	인터페이스	OpenMP	Cuda	OPenCL	멀티GPU	분산
Google	Linux, Mac, Window	Android, iOS	Python, C++	Python, C/C++, Java, Go	N	Y	-	Y	Y

## 장점

- Low-level / High level API 모두 제공
- 방대한 사용자 커뮤니티
- 문서화가 잘되어 있음
- 시각화 도구 제공(TensorBoard)

## 단점

- 런타임 중 그래프 변경 안됨
- 비교적 느림
- CUDA 연결 이슈에 민감함

# 딥러닝 프레임워크 비교

PIAI Research Department

## K Keras

주체	플랫폼	모바일	언어	인터페이스	OpenMP	Cuda	OPenCL	멀티GPU	분산
Francois Chollet	Linux, Mac, Window	-	Python	Python	Y(Theano) N(TF)	Y	-	Y	-

### 장점

- 직관적인 API 인터페이스
- Caffe, Torch, Tensorflow 등 다양한 딥러닝 프레임워크 모델 import 가능 제공
- 문서화가 잘되어 있음

### 단점

- 텐서플로우의 단점과 유사함

# Keras 뉴토리얼

PIAI Research Department

## K Keras

- tensorflow.keras (tf.keras) module
- Part of core TensorFlow since v1.14
- In-browser with GPU acceleration (WebKeras, Keras.js, WebDNN⋯⋯)
- Android (TF, TF Lite), iPhone (native CoreML support), Raspberry Pi, JVM
- 쉬움!

tf.keras

TensorFlow

GPU

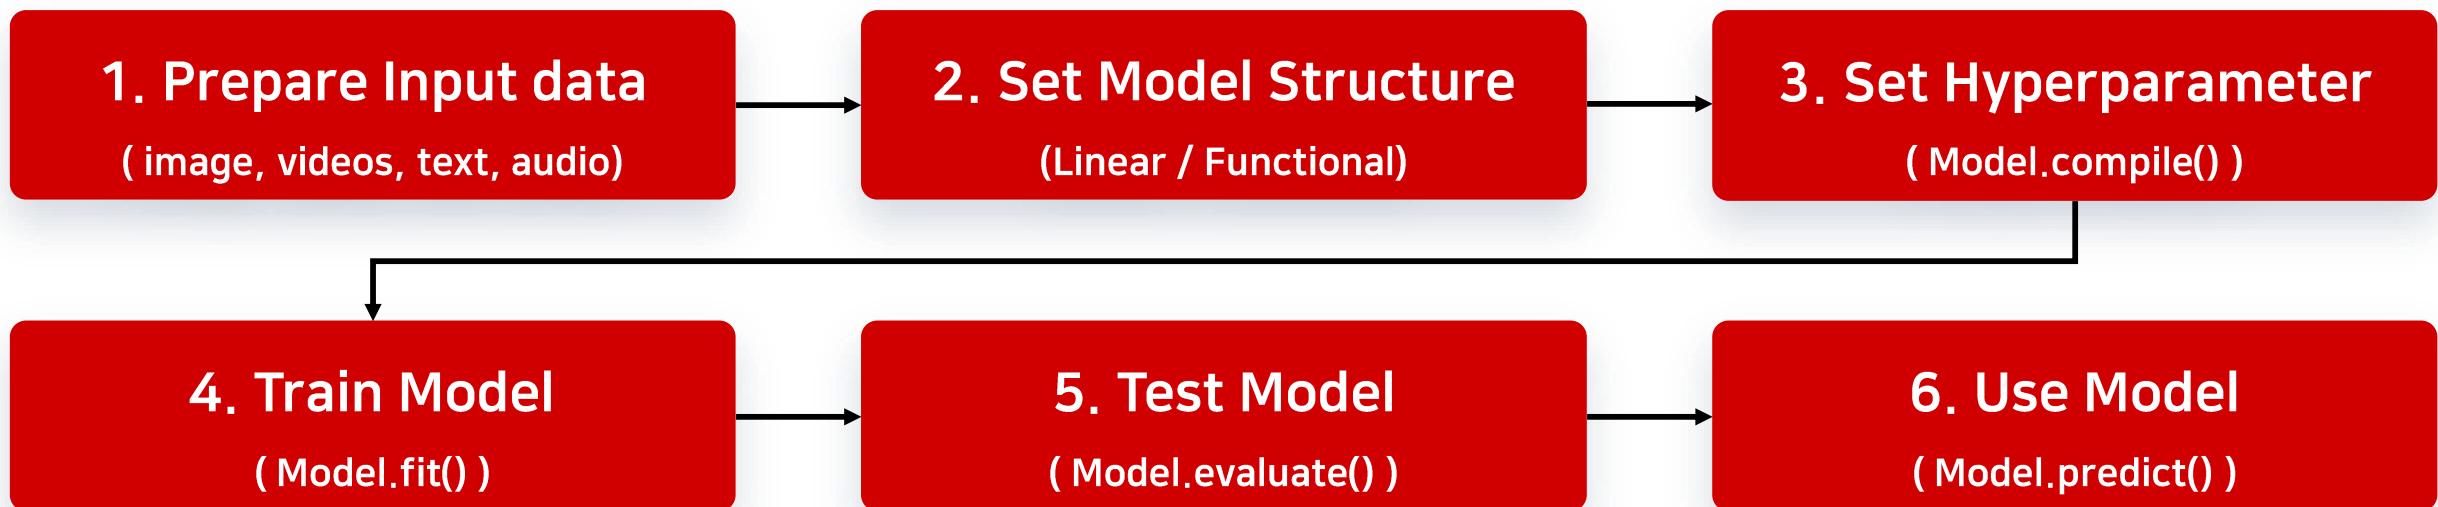
CPU

TPU

# Keras Framework Flow

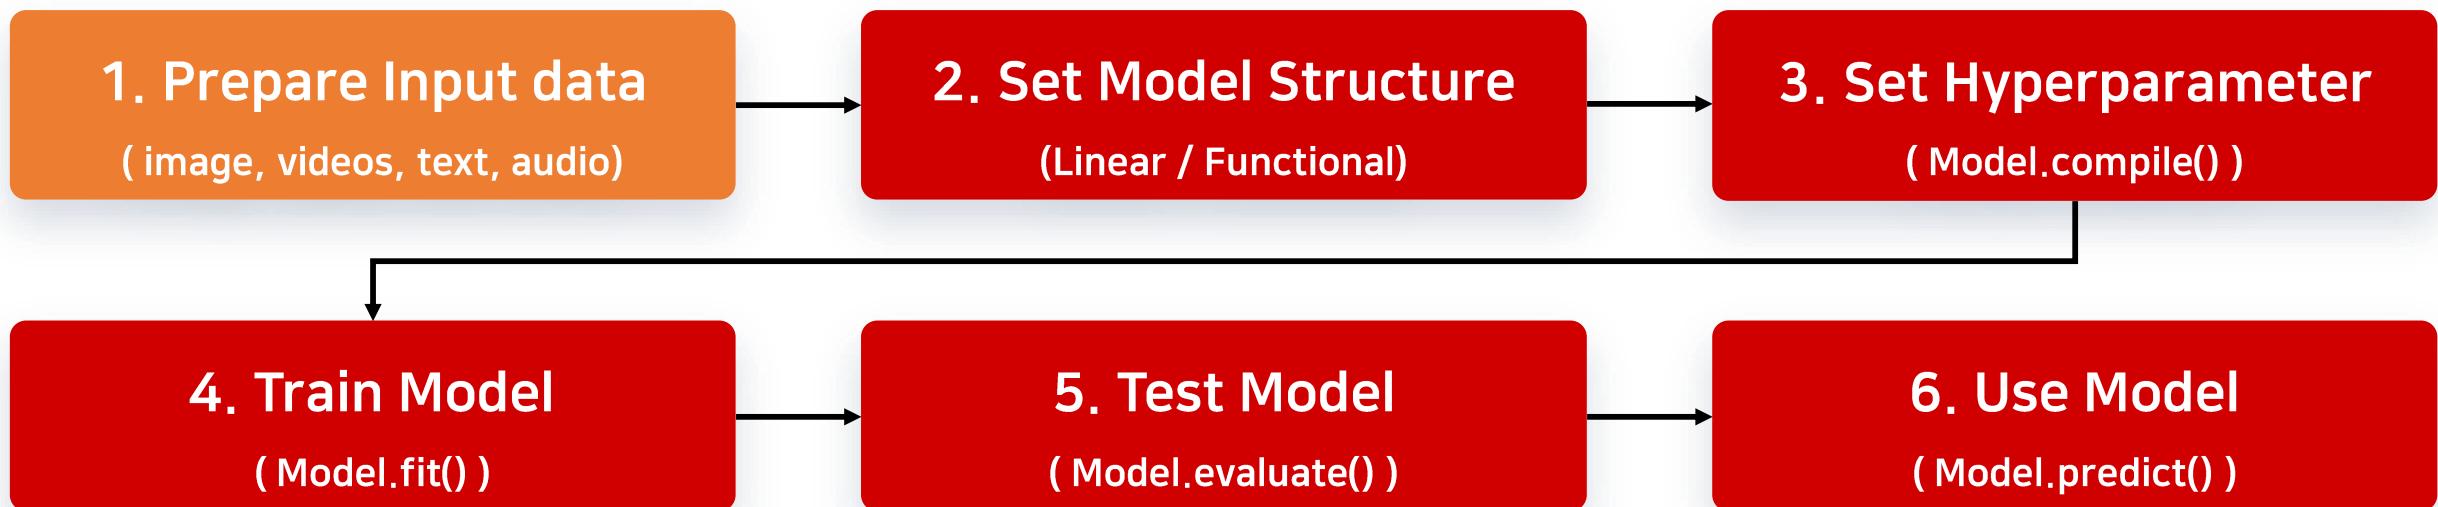
PIAI Research Department

- Keras 주요 학습과정



# Keras Framework Flow

PIAI Research Department



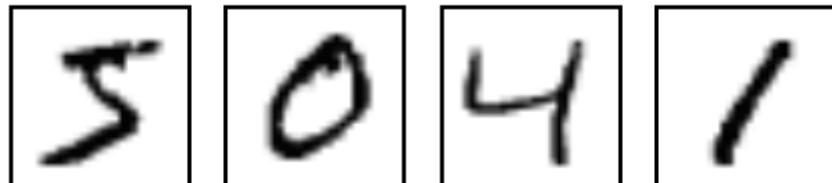
# Input Data Preparation

PIAI Research Department

## - MNIST Dataset

0 0 0 0 0 0 0 0 0 0 0 0  
1 1 1 1 1 1 1 1 1 1 1 1  
2 2 2 2 2 2 2 2 2 2 2 2  
3 3 3 3 3 3 3 3 3 3 3 3  
4 4 4 4 4 4 4 4 4 4 4 4  
5 5 5 5 5 5 5 5 5 5 5 5  
6 6 6 6 6 6 6 6 6 6 6 6  
7 7 7 7 7 7 7 7 7 7 7 7  
8 8 8 8 8 8 8 8 8 8 8 8  
9 9 9 9 9 9 9 9 9 9 9 9

Image



Label

5

0

4

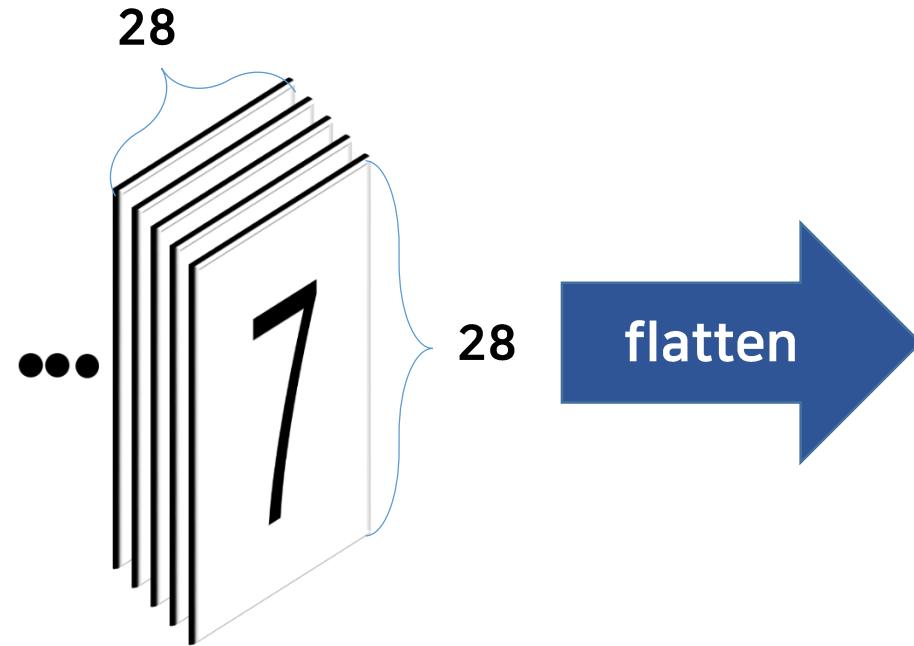
1

- 손으로 쓴 숫자들로 이루어진 데이터셋
- 0~9의 10개 클래스로 구성
- 28x28크기의 grayscale 이미지와 라벨
- Training sample : 60,000개
- Test sample : 10,000개

# Input Data Preparation

PIAI Research Department

Image



Label

..... 4 5 7

one-hot  
encoding

$$28 \times 28 = 784$$

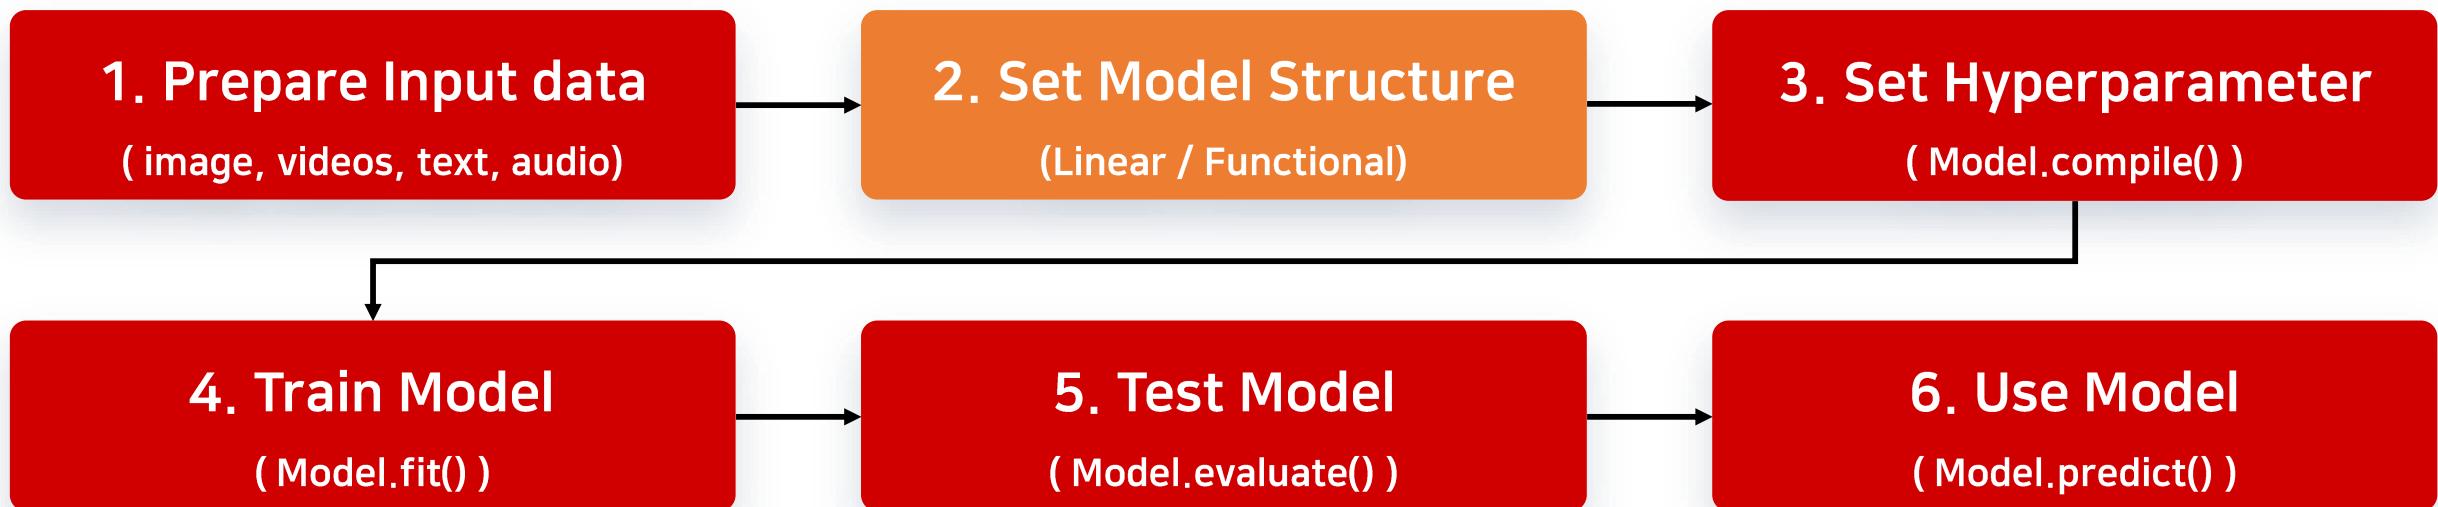
0	0	0	0	1	0	0	0	0	0
0	0	0	0	0	1	0	0	0	0
0	0	0	0	0	0	0	1	0	0

.....

.....

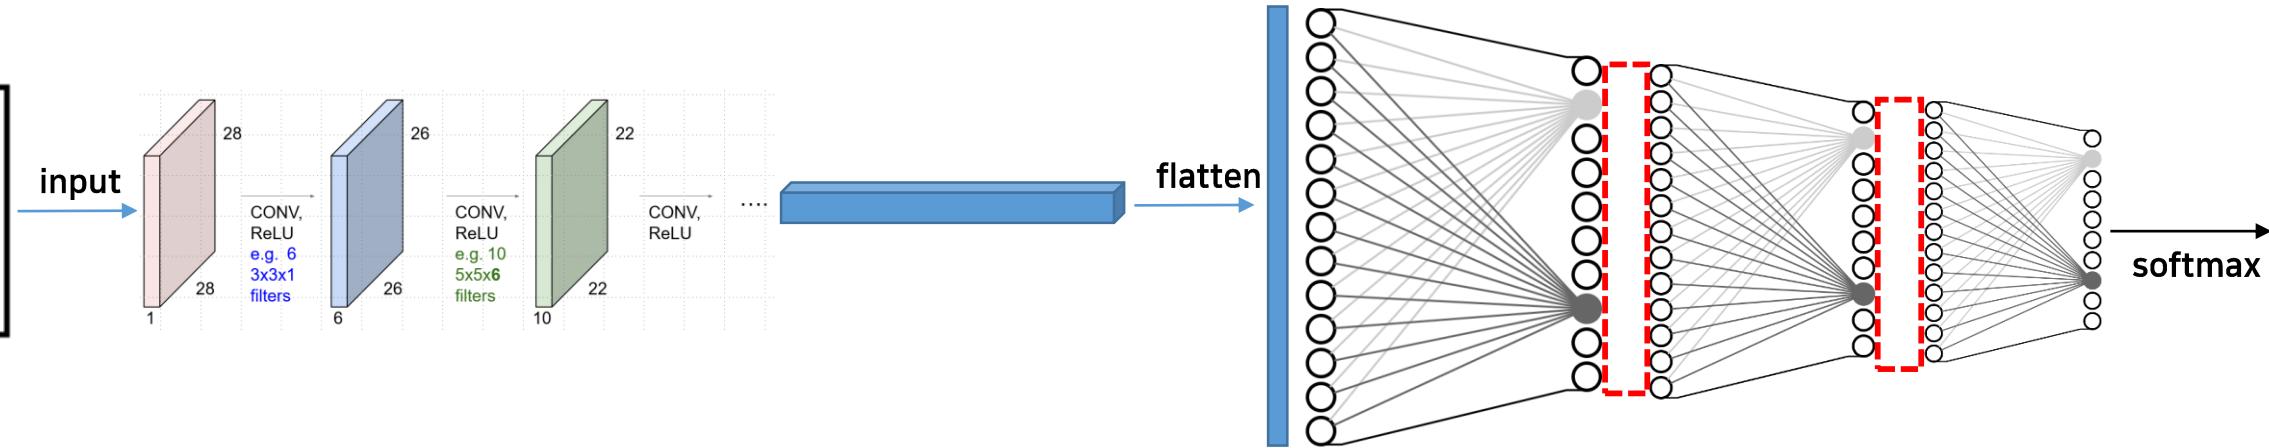
# Keras Framework Flow

PIAI Research Department



# Overview of Image classification

PIAI Research Department

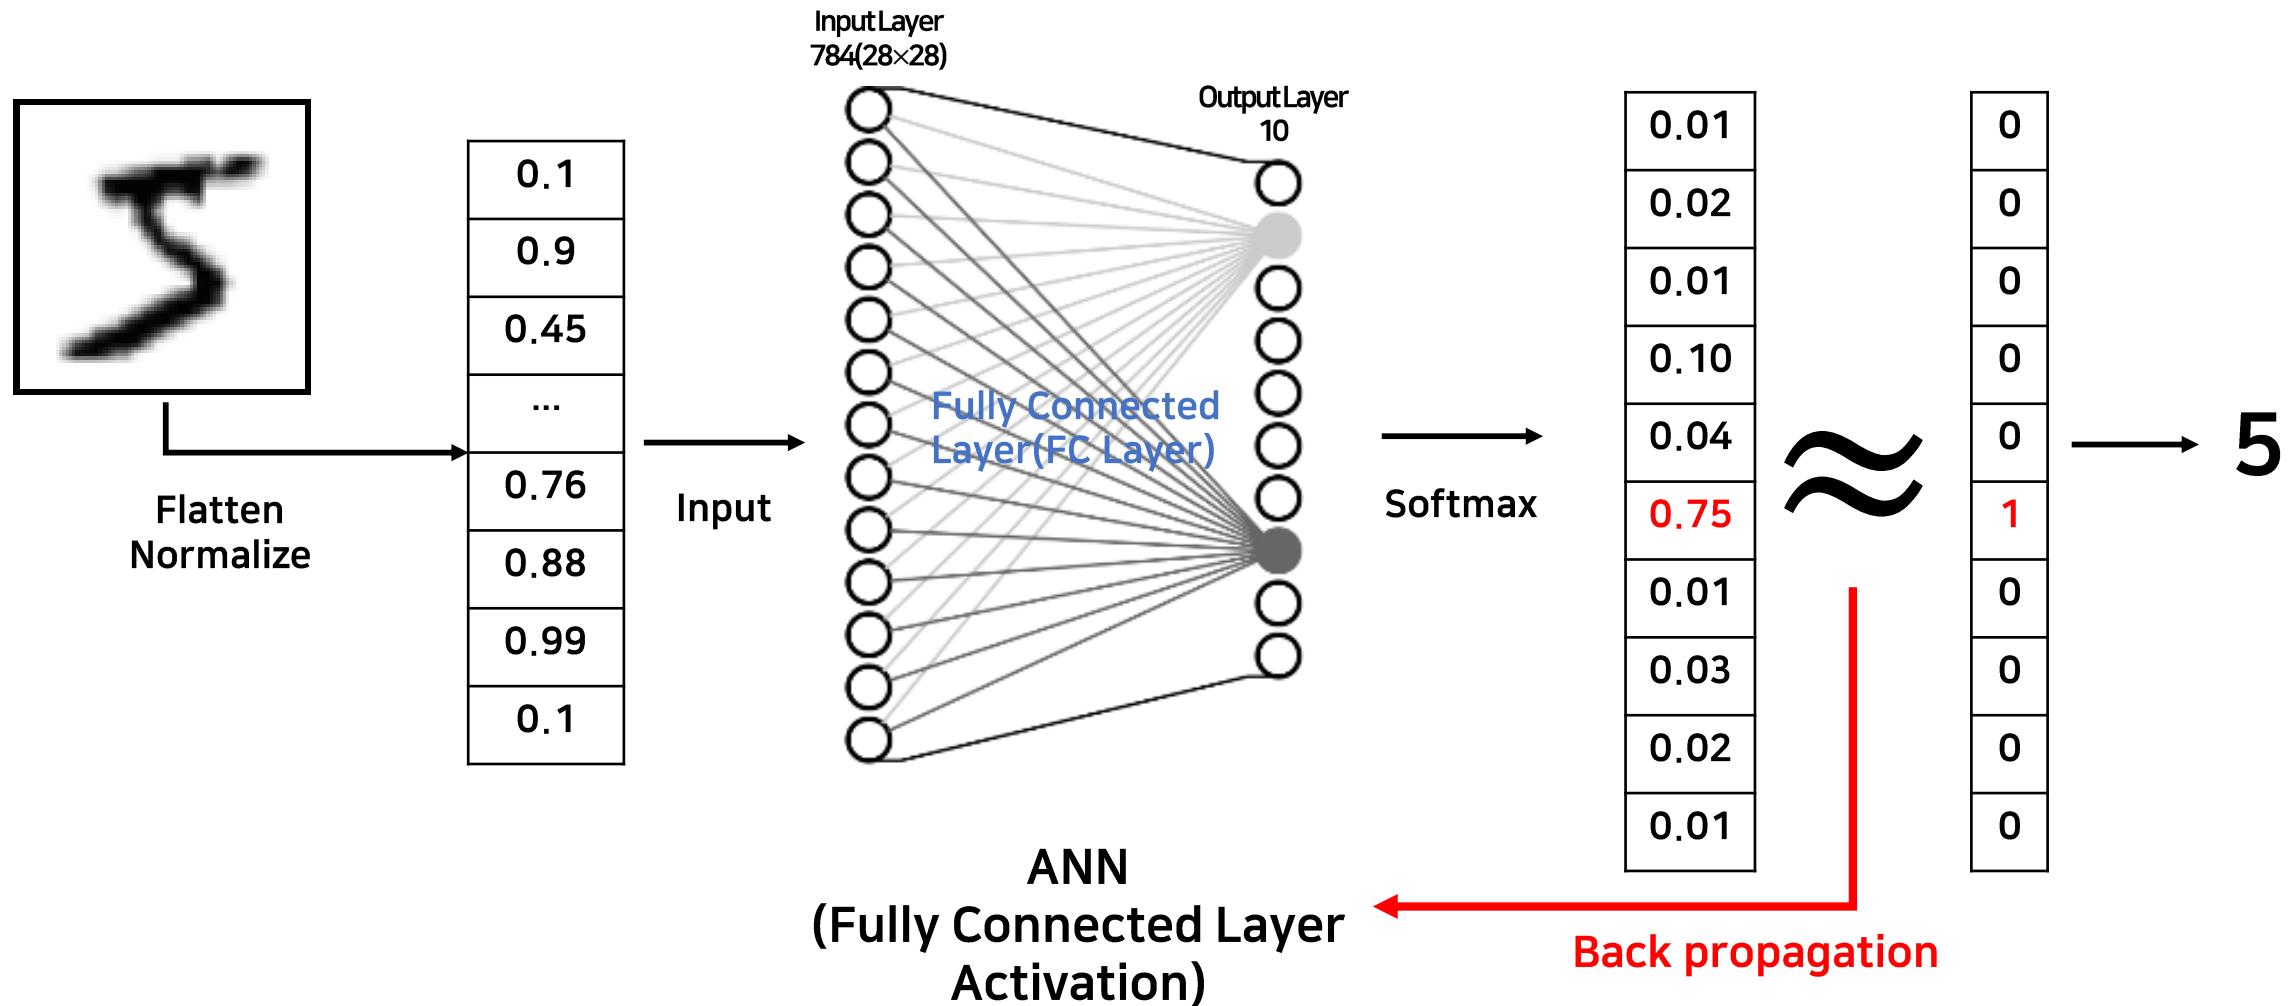


**Feature extraction**  
(Convolution layer  
Pooling layer)

**Classifier**  
(Fully Connected layer  
Activation layer)

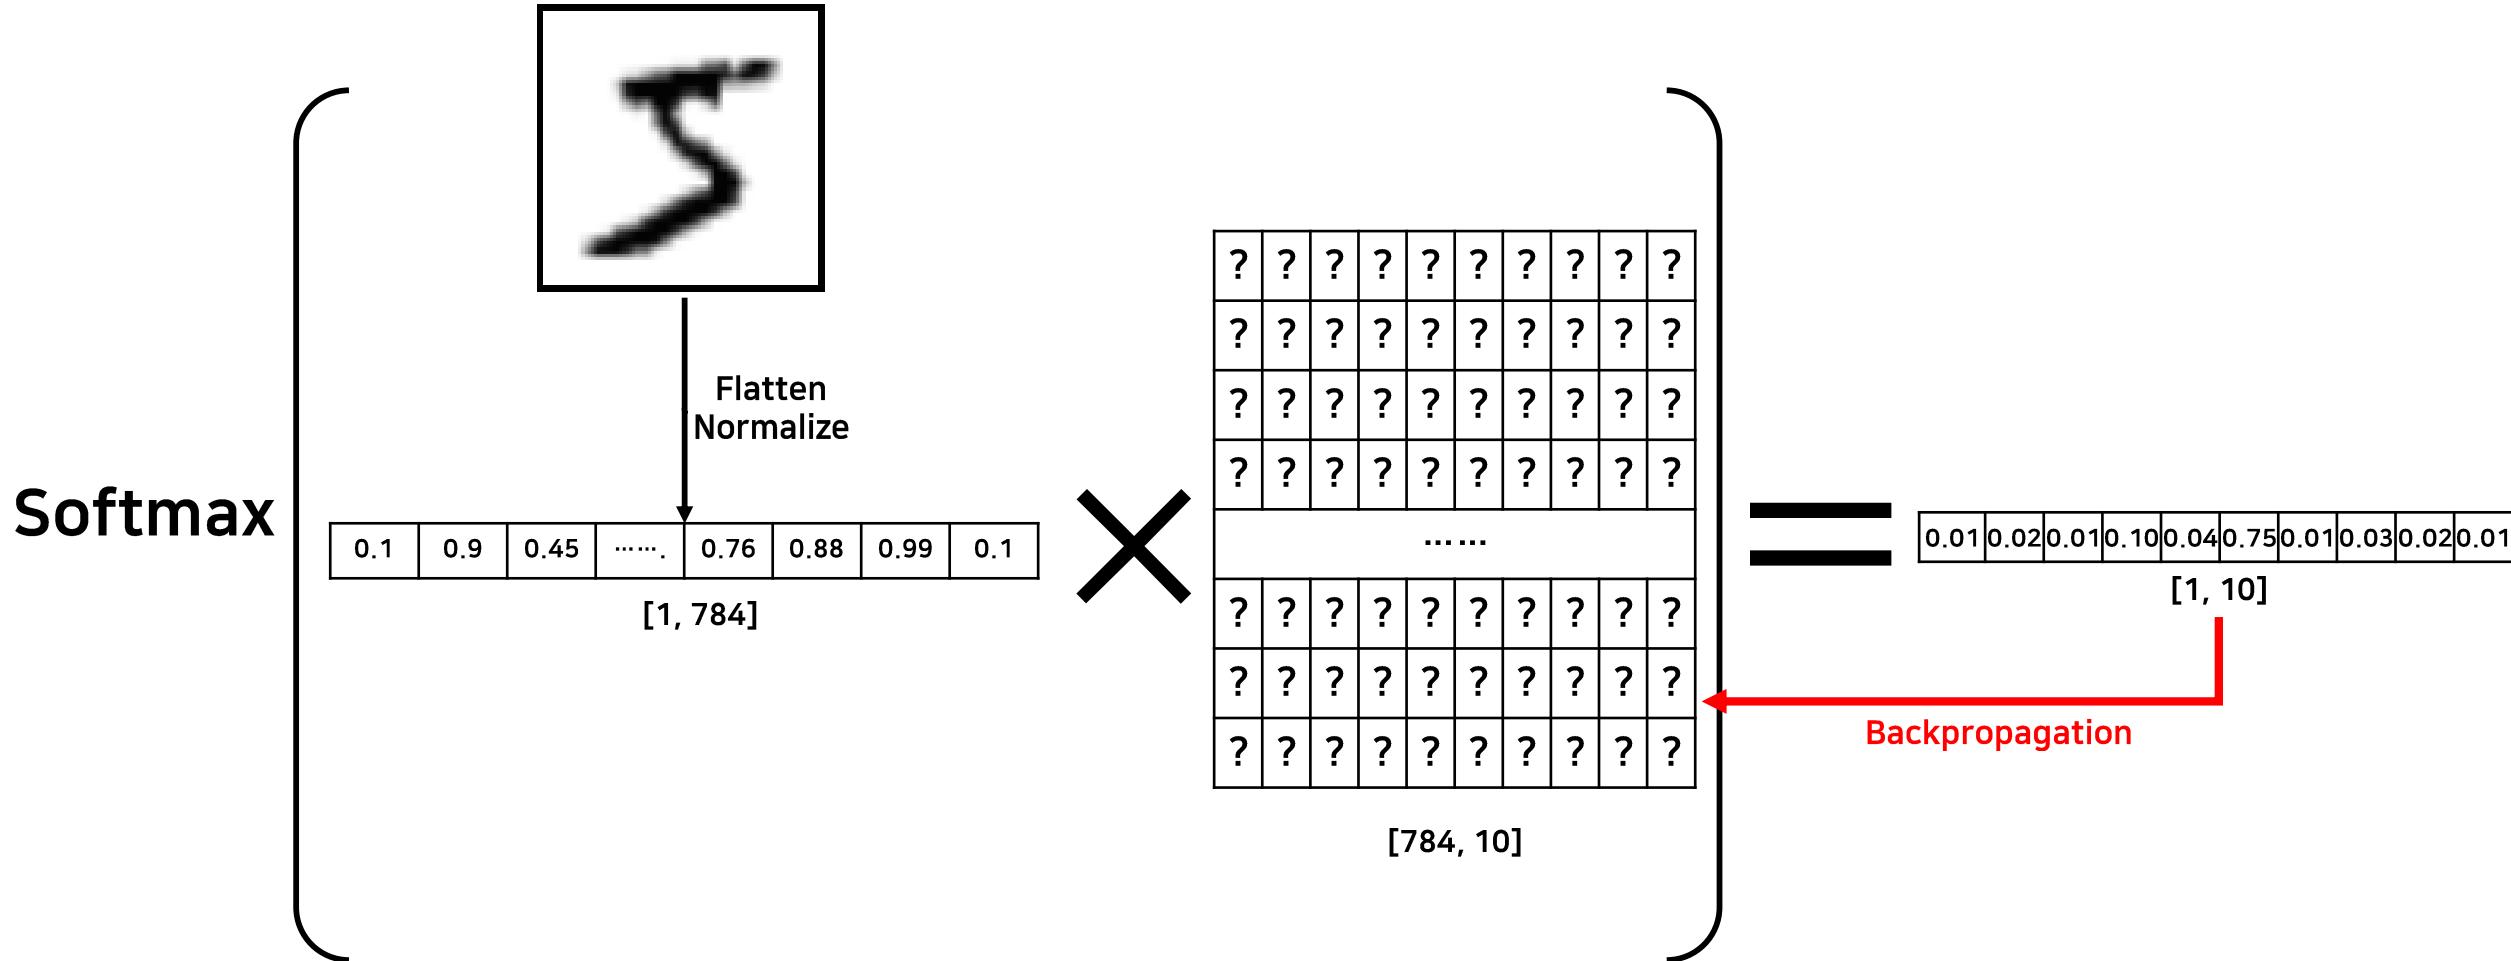
# Overview of Classifier

PIAI Research Department



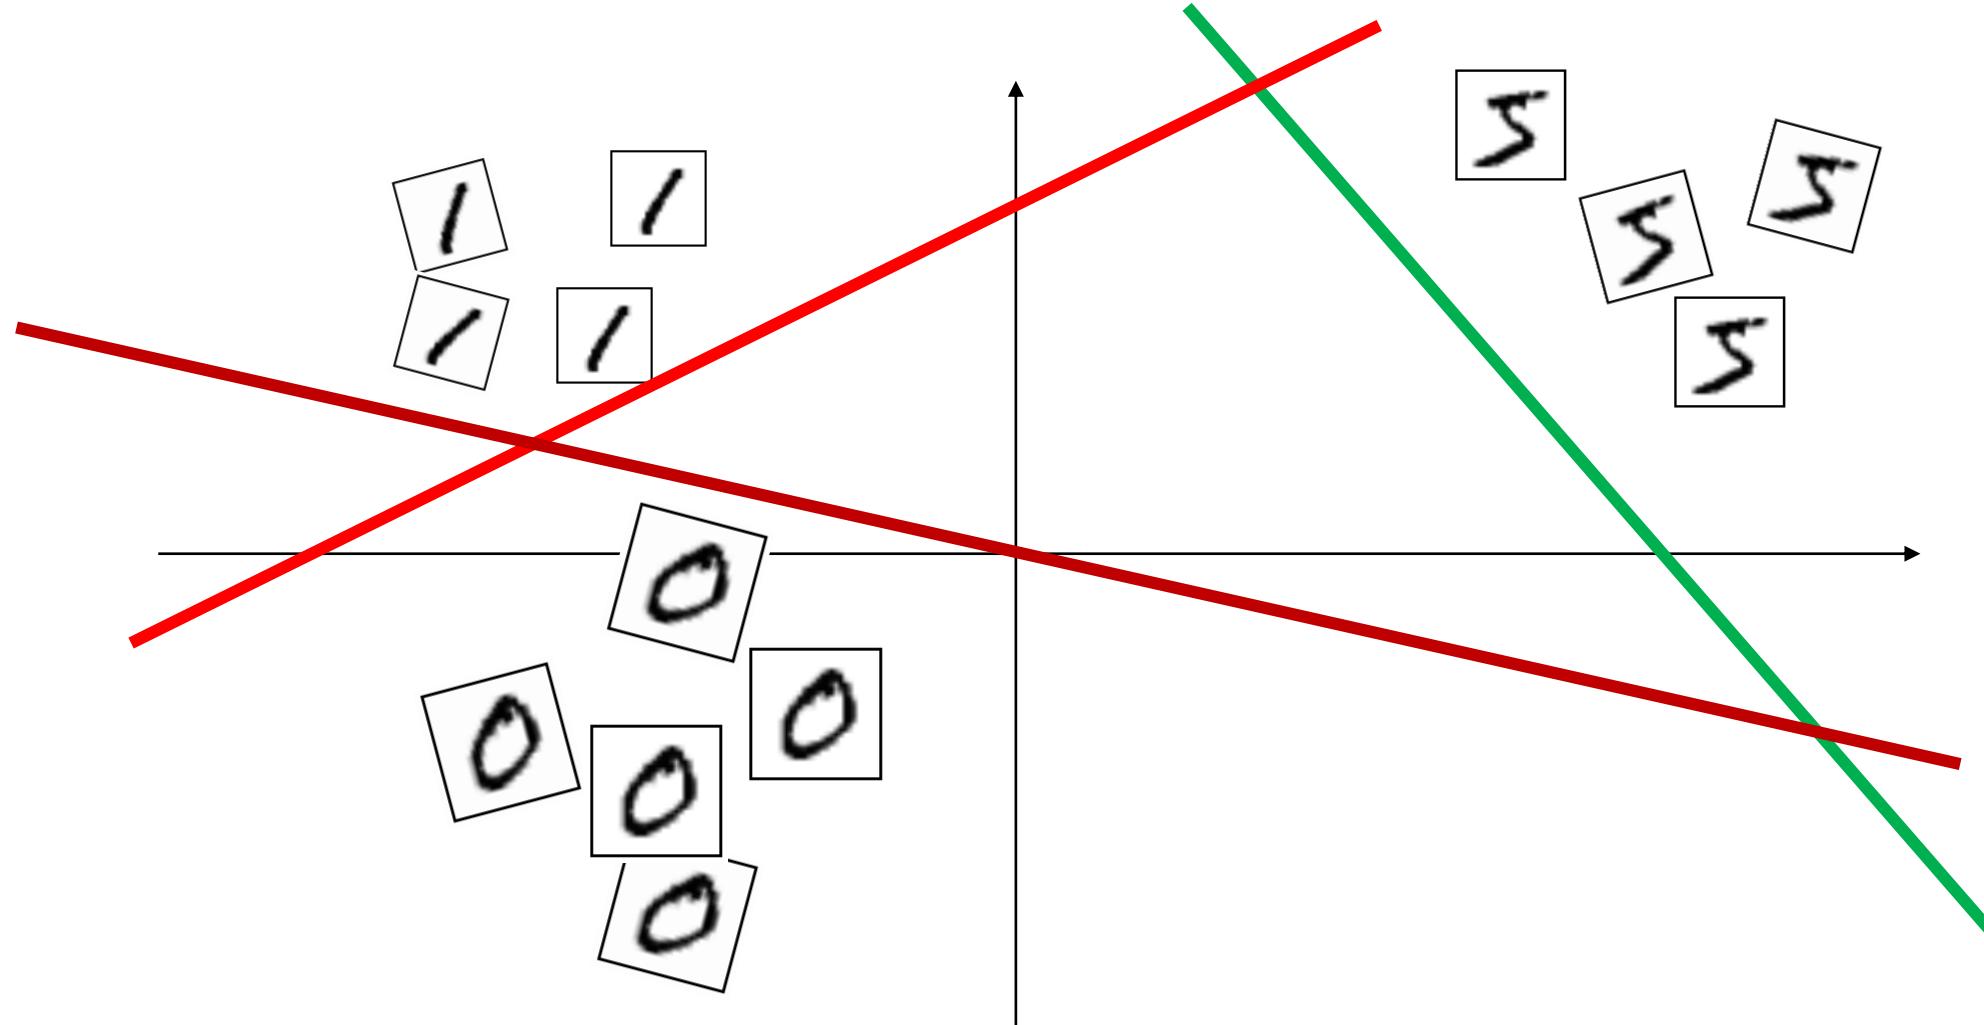
# Linear Classifier

PIAI Research Department



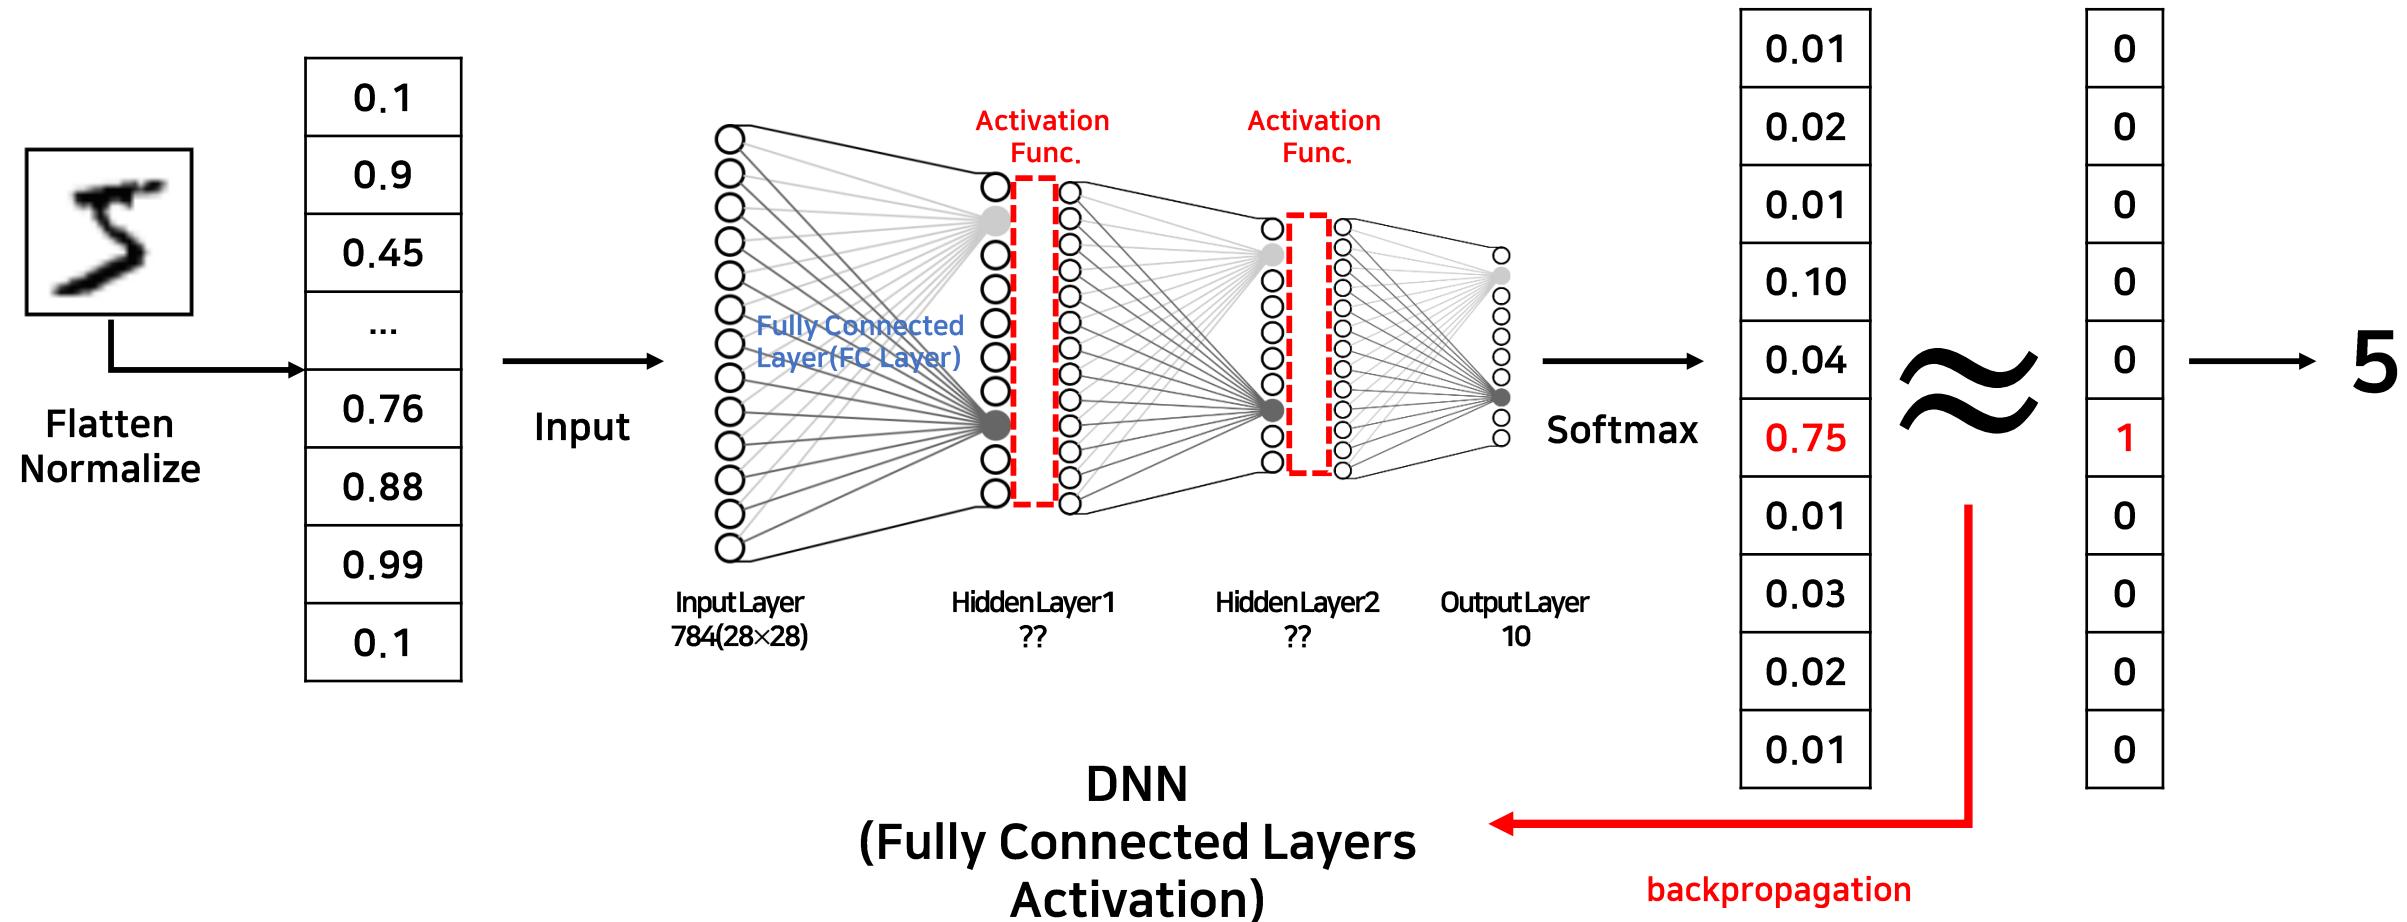
# Linear Classifier

PIAI Research Department



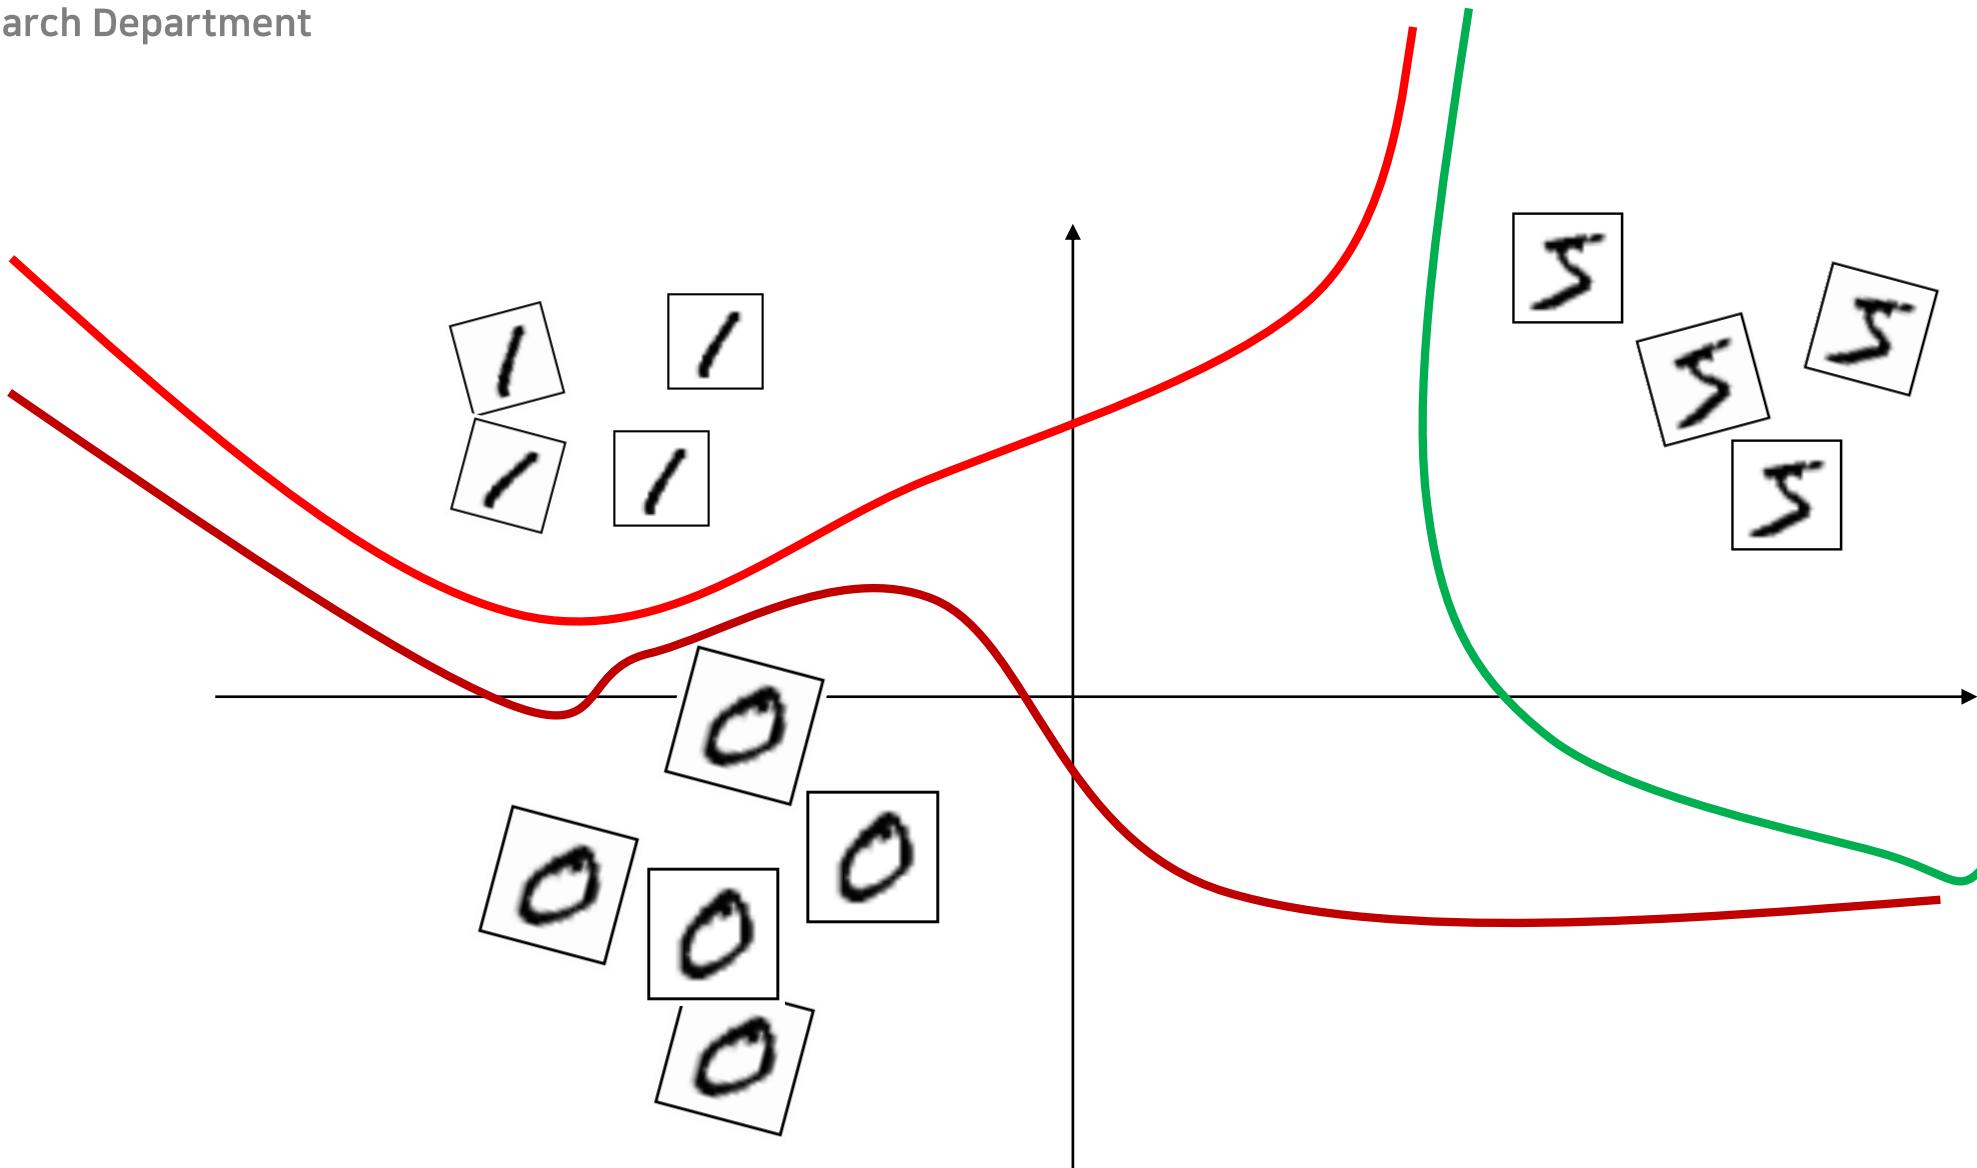
# Overview of DNN

PIAI Research Department



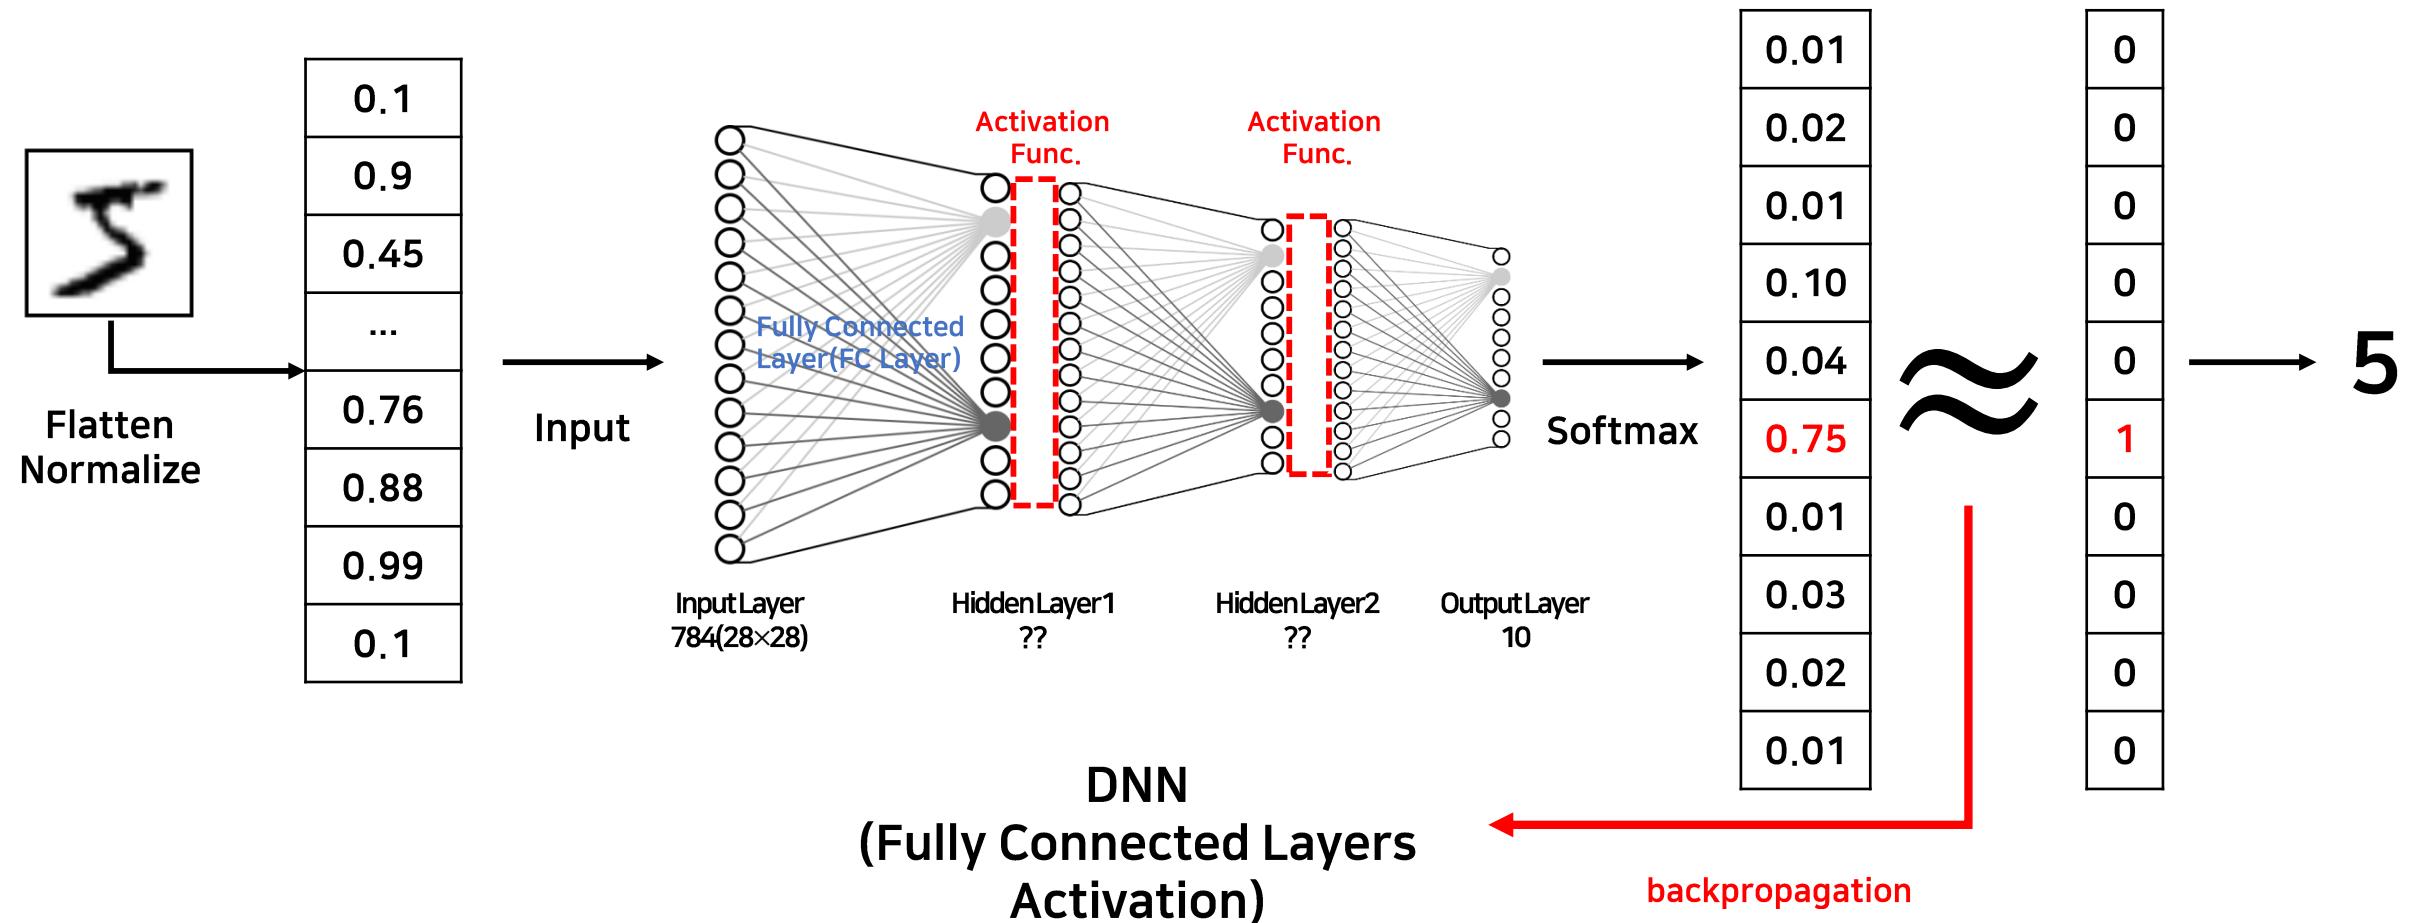
# DNN Classifier

PIAI Research Department



# Classifier

PIAI Research Department

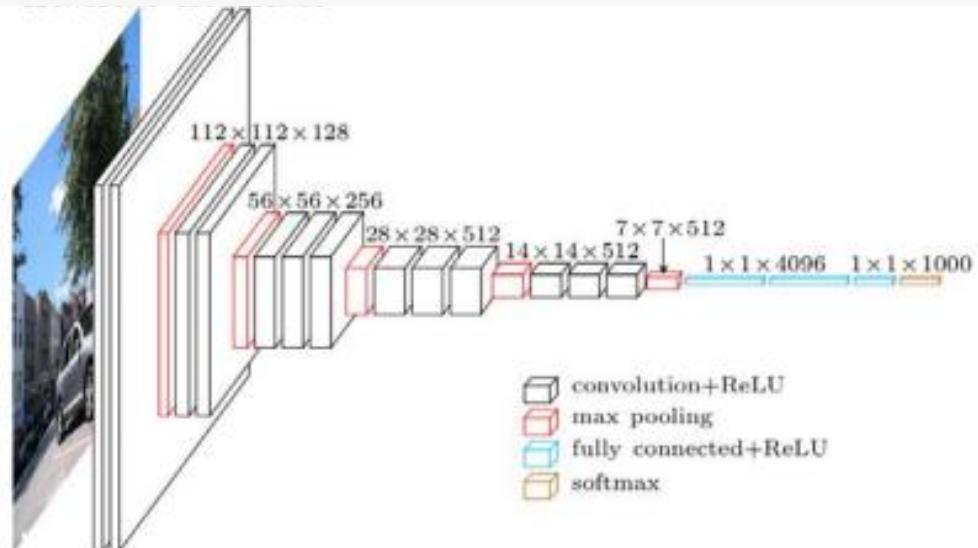


# Network Definition

PIAI Research Department

## 2. Define the model (Sequential style)

```
def DNN_seq(n_in, n_out):
    model = Sequential()
    model.add(Dense(units=256, input_shape=(n_in,), activation='relu'))
    model.add(Dense(units=128, input_shape=(256,), activation='relu'))
    model.add(Dense(units=64, input_shape=(128,), activation='relu'))
    model.add(Dense(units=32, input_shape=(64,), activation='relu'))
    model.add(Dense(units=n_out, input_shape=(32,), activation='softmax'))
    return model
```



- **Linear stack of layers**
- **Useful for building simple models**
- **Simple classification network**
- **Encoder – Decoder models**

# Network Definition

PIAI Research Department

## 2. Define the model (Sequential style)

```
def DNN_seq(n_in, n_out):  
    model = Sequential()  
    model.add(Dense(units=256, input_shape=(n_in,), activation='relu'))  
    model.add(Dense(units=128, input_shape=(256,), activation='relu'))  
    model.add(Dense(units=64, input_shape=(128,), activation='relu'))  
    model.add(Dense(units=32, input_shape=(64,), activation='relu'))  
    model.add(Dense(units=n_out, input_shape=(32,), activation='softmax'))  
    return model
```

- Sequential : Sequential 스타일로 진행하겠다고 설정
- Dense : Fully Connected Layer 종류
- Units : output 원소 개수
- Input\_shape : input의 크기
- Activation : activation 함수 설정

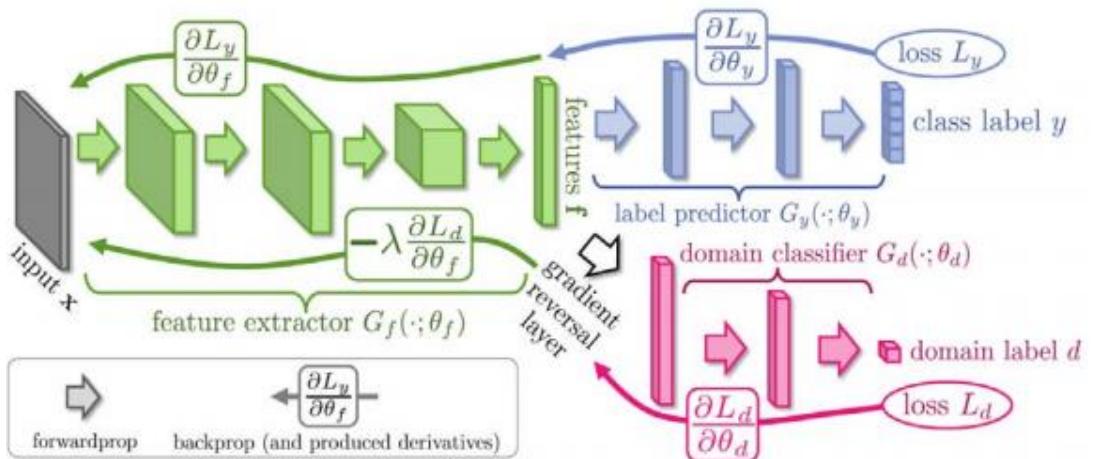
# Network Definition

PIAI Research Department

## 2. Define the model (Functional style)

```
def DNN_func(n_in, n_out):
    x = Input(shape=(n_in,))
    x = Dense(256)(x)
    x = Activation('relu')(x)
    x = Dense(128)(x)
    x = Activation('relu')(x)
    x = Dense(64)(x)
    x = Activation('relu')(x)
    x = Dense(32)(x)
    x = Activation('relu')(x)
    x = Dense(n_out)(x)
    y = Activation('softmax')(x)
    model = Model(inputs = x, outputs = y)
    return model
```

- Multi-input and Multi-output models
- Complex models which forks into 2 or more branches
- Models with shared (Weights) layers



# Network Definition

PIAI Research Department

## 2. Define the model (Functional style)

```
def DNN_func(n_in, n_out):
    x = Input(shape=(n_in,))
    x = Dense(256)(x)
    x = Activation('relu')(x)
    x = Dense(128)(x)
    x = Activation('relu')(x)
    x = Dense(64)(x)
    x = Activation('relu')(x)
    x = Dense(32)(x)
    x = Activation('relu')(x)
    x = Dense(n_out)(x)
    y = Activation('softmax')(x)
    model = Model(inputs = x, outputs = y)
    return model
```

- **Input : Input Layer로 정의**
- **Dense(256)(x) : x layer를 input으로 256크기의 output이 나오도록 Fully Connected layer를 구성**
- **Activation('relu')(x) : x layer를 입력해 relu 활성화 함수를 적용**
- **Model(inputs = x, outputs = y) : x를 입력해서 y 가 출력될 수 있도록 Model을 정의**

# Network Definition

PIAI Research Department

## 2. Define the model

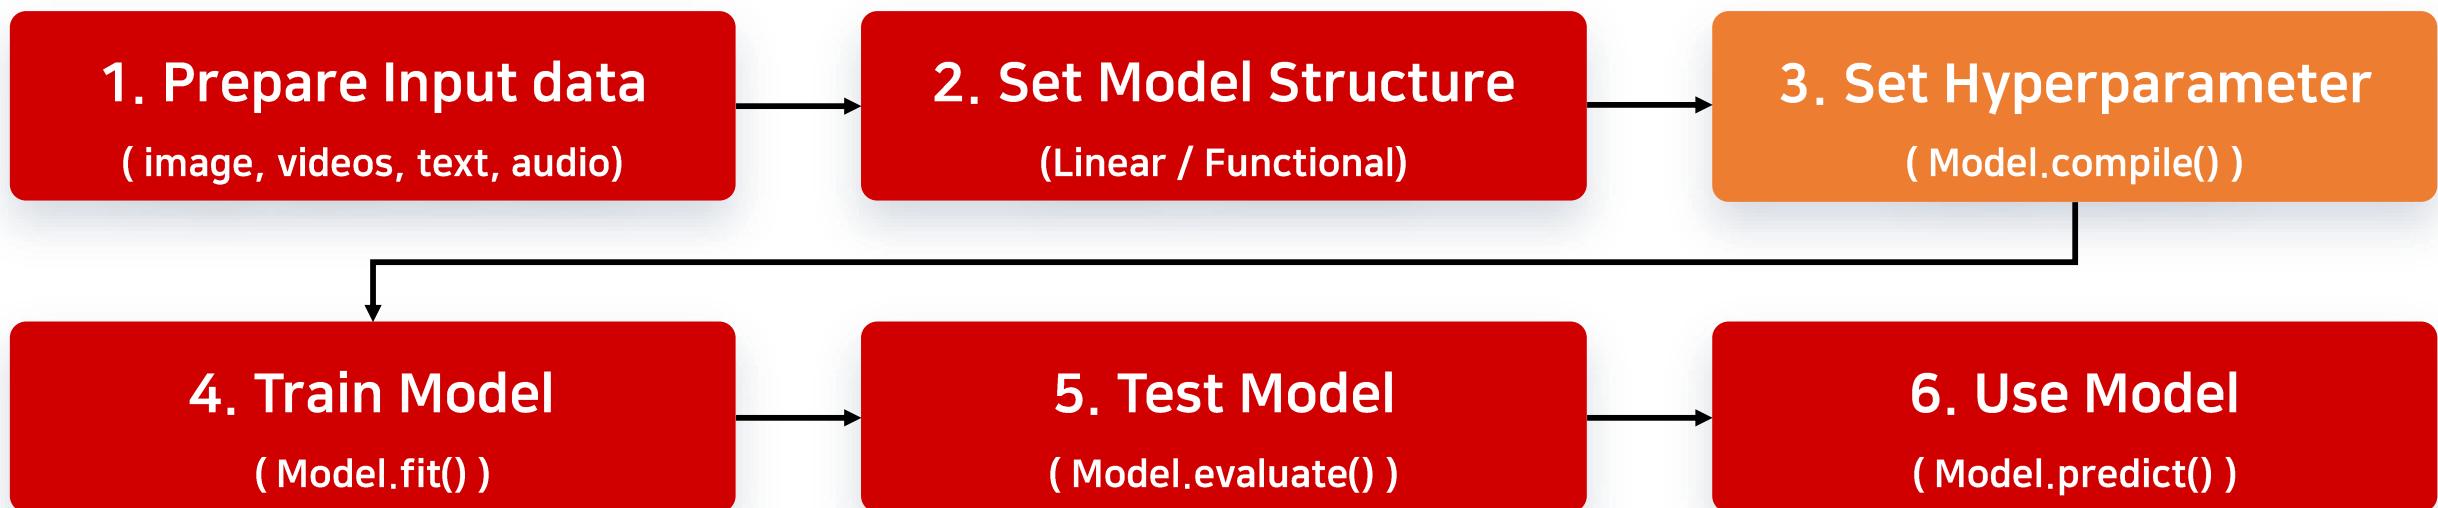
```
model = DNN_seq(n_in, n_out)
model.summary()
```

Model: "sequential\_4"

Layer (type)	Output Shape	Param #
<hr/>		
dense_17 (Dense)	(None, 256)	200960
dense_18 (Dense)	(None, 128)	32896
dense_19 (Dense)	(None, 64)	8256
dense_20 (Dense)	(None, 32)	2080
dense_21 (Dense)	(None, 10)	330
<hr/>		
Total params: 244,522		
Trainable params: 244,522		
Non-trainable params: 0		

# Keras Framework Flow

PIAI Research Department



# Model Setting

PIAI Research Department

## 3. Model.compile() (Set Loss / Optimizer and Metrics)

```
model.compile(loss='categorical_crossentropy',  
              optimizer='adam',  
              metrics=['accuracy'])
```

Loss Functions: 알고리즘이 예측한 값과 실제 정답의 차이를 비교하기 위한 함수

종류

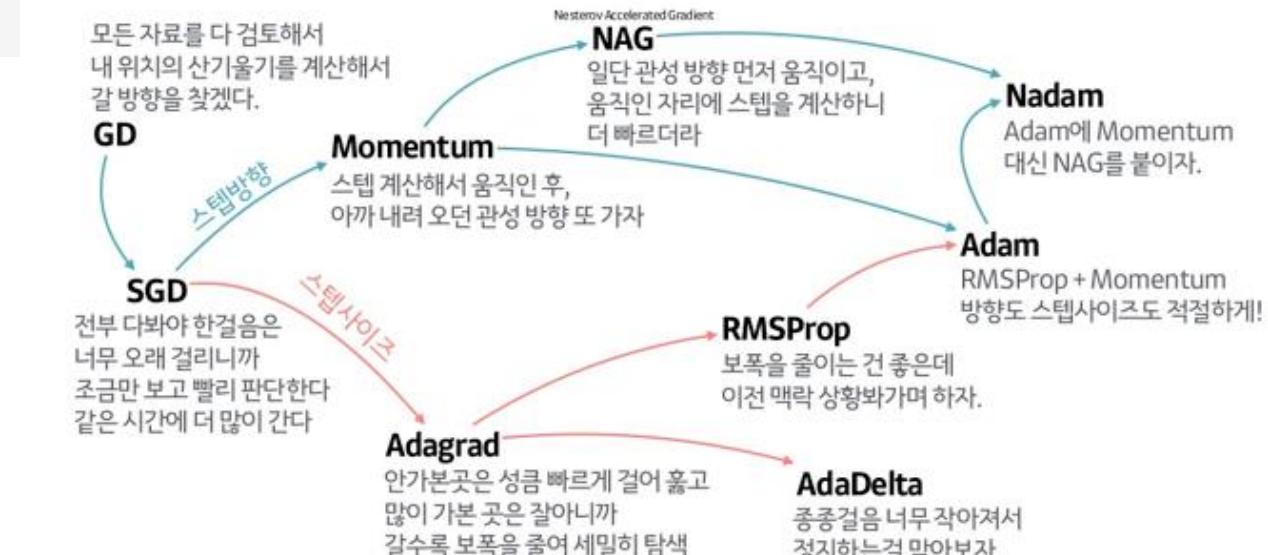
- Probabilistic losses: binary\_crossentropy, categorical\_crossentropy, sparse\_categorical\_crossentropy, poisson, kl\_divergence
- Regression loss: rmse, mse, mae, mape, msle, cosine\_similarity
- Hinge loss: hinge, squared\_hinge, categorical\_hinge,

# Model Setting

PIAI Research Department

## 3. Model.compile() (Set optimizer and loss function)

```
model.compile(loss='categorical_crossentropy',
               optimizer='adam',
               metrics=['accuracy'])
```



출처 : <https://www.slideshare.net/yongho/ss-79607172>

Optimizer Loss function의 최솟값을 찾아주고자 할 때 수행할 알고리즘

종류 : sgd, RMSprop, **Adam**, Adadelta, Adagrad, Adamax, Nadam, Ftrl

# Model Setting

PIAI Research Department

## 3. Model.compile() (Set optimizer and loss function)

```
model.compile(loss='categorical_crossentropy',
               optimizer='adam',
               metrics=['accuracy'])
```

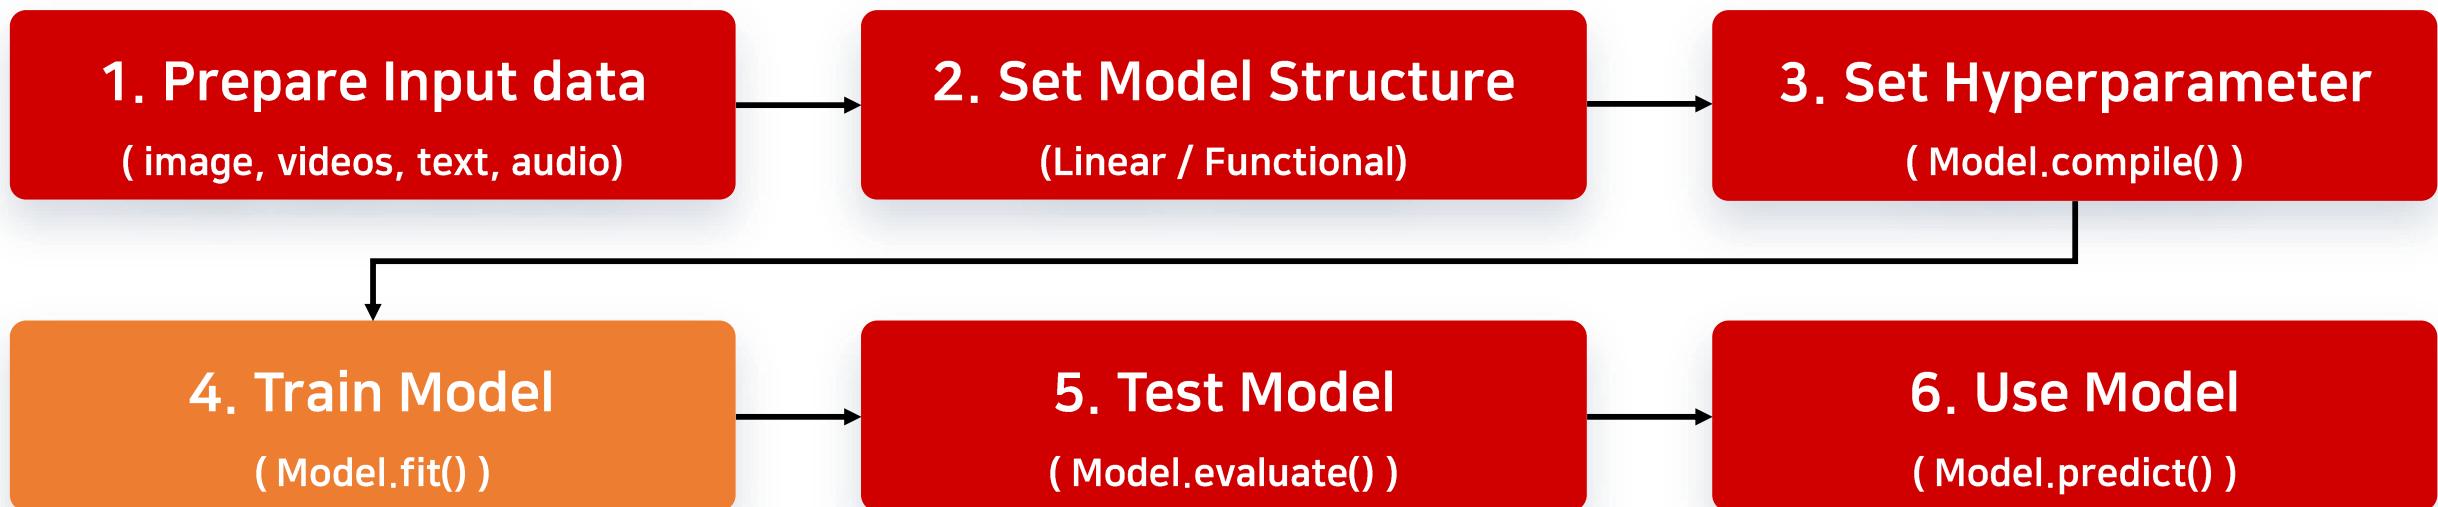
Metrics : 검증 데이터에서의 학습 모델의 성능에 대한 평가 지표 설정

종류:

- Loss
- accuracy, top\_k\_categorical\_accuracy
- Recall, Precision, AUC
- MeanIoU

# Keras Framework Flow

PIAI Research Department



# Model Training

PIAI Research Department

## 4. Model.fit() (Train model)

```
model.fit(train_X, train_Y, epochs=epochs, batch_size=batch_size, validation_data=(vali_X, vali_Y), shuffle=False, callbacks=[checkpointer])  
checkpointer=ModelCheckpoint(filepath=modelpath, monitor='val_acc', verbose=0, save_best_only=True)
```

- Train\_X: Training data
- Train\_Y: Target label
- validation\_data: Tuple (vali\_x, vali\_y)
- validation\_split: Fraction of the training data to be used as validation data (0~1 사이값)
- shuffle: whether to shuffle the training data before each epoch (Boolean)
- verbose: Verbosity mode(0, 1, or 2)

# Model Training

PIAI Research Department

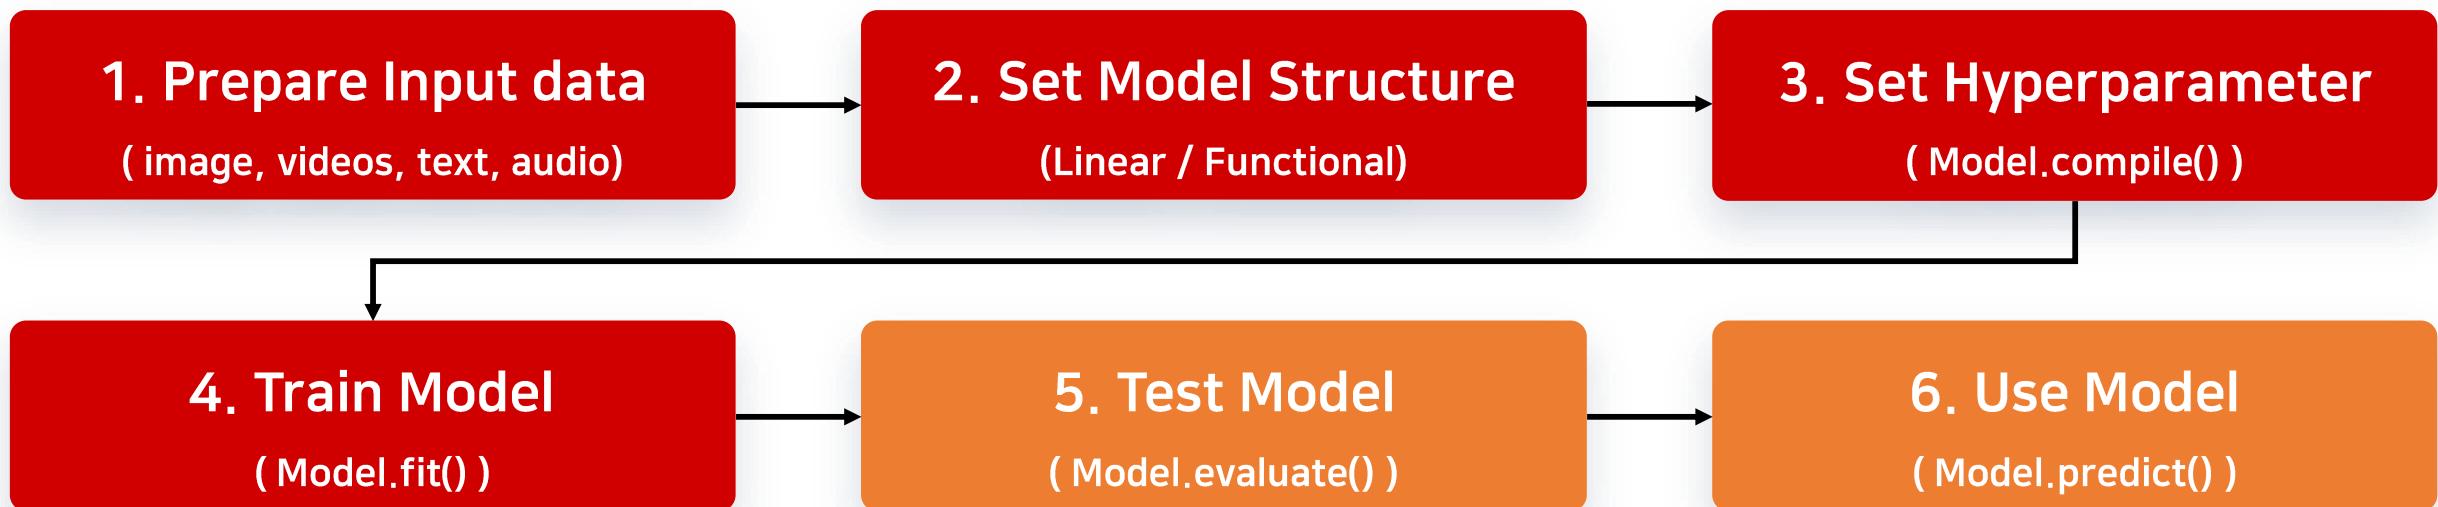
## 4. Model.fit() (Train model)

```
model.fit(train_X, train_Y, epochs=epochs, batch_size=batch_size, validation_data=(vali_X, vali_Y), shuffle=False, callbacks=[checkpointer])  
checkpointer=ModelCheckpoint(filepath=modelpath, monitor='val_acc', verbose=0, save_best_only=True)
```

- **epochs:** Number of epochs to train the model
  - **batch\_size:** Number of samples per gradient update
- 
- 1 Epoch : 전체 데이터셋에 대해 한번 학습을 완료한 상태를 의미(보통 1 Epoch 후 validation 진행)
  - Iteration : 1 Epoch을 완료하기 위해 필요한 Pass 회수( $\text{batch\_size} \times \text{Iteration} \approx \text{Dataset Size}$ )

# Keras Framework Flow

PIAI Research Department



# Model Application

PIAI Research Department

## 5. Model.evaluate() (Test model)

```
loss_and_accuracy = model.evaluate(X_test, Y_test, batch_size=128)
print('loss : %.4f, accuracy : %.4f' % (loss_and_accuracy[0], loss_and_accuracy[1]))
```

- **x:** test data
- **y:** target label
- **batch\_size:** Number of samples per evaluation step
- **verbose:** Verbosity mode

## 6. Model.predict() (Use model)

```
model.predict(x, batch_size=128)
```

- **x:** input data
- **batch\_size:** Number of samples per predict
- **verbose:** Verbosity mode

# Code Running

**(student) 1\_Keras Basic & Classifier.ipynb**



# PyTorch Basic

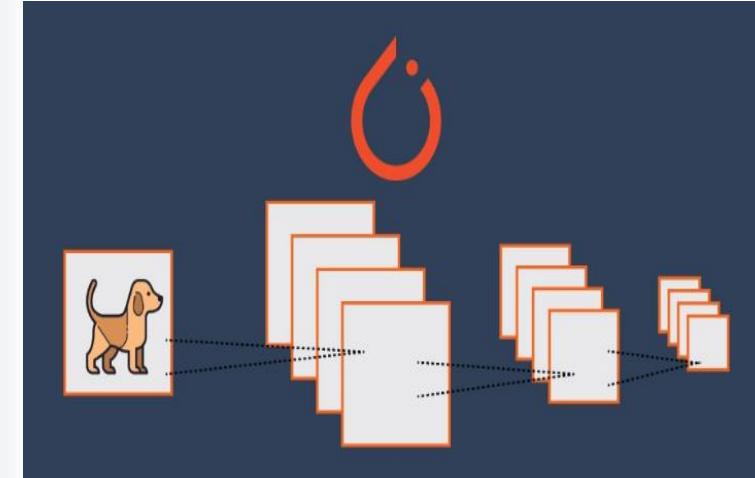
I-Eon Na

# PyTorch Tutorial

PIAI Research Department



- PyTorch (`torch.nn`) module
  - Base on Torch and Caffe2
  - similar Deep Learning library to TensorFlow
- 
- Made by Facebook AI Research Team
  - Simple to make and edit network and parameters on GPU



# Keras VS PyTorch

PIAI Research Department

## Keras

간단..?

```
model = Sequential()
model.add(Conv2D(32, (3, 3), activation='relu'))
model.add(MaxPool2D())
model.add(Conv2D(16, (3, 3), activation='relu'))
model.add(MaxPool2D())
model.add(Flatten())
model.add(Dense(10, activation='softmax'))
```

동일 로직, 다른 코드

- 데이터 전처리 과정 간편
- 단일 코드로 간단한 모델 제작 가능
- Verbose 기능 제공(학습 추이 출력)

## PyTorch

```
class Net(nn.Module):
    def __init__(self):
        super(Net, self).__init__()

        self.conv1 = nn.Conv2d(3, 32, 3, 1)
        self.conv2 = nn.Conv2d(32, 16, 3, 1)
        self.fc1 = nn.Linear(16 * 6 * 6, 10)
        self.pool = nn.MaxPool2d(2, 2)

    def forward(self, x):
        x = self.pool(F.relu(self.conv1(x)))
        x = self.pool(F.relu(self.conv2(x)))
        x = x.view(-1, 16 * 6 * 6)
        x = F.log_softmax(self.fc1(x))

        return x
```

복잡..?

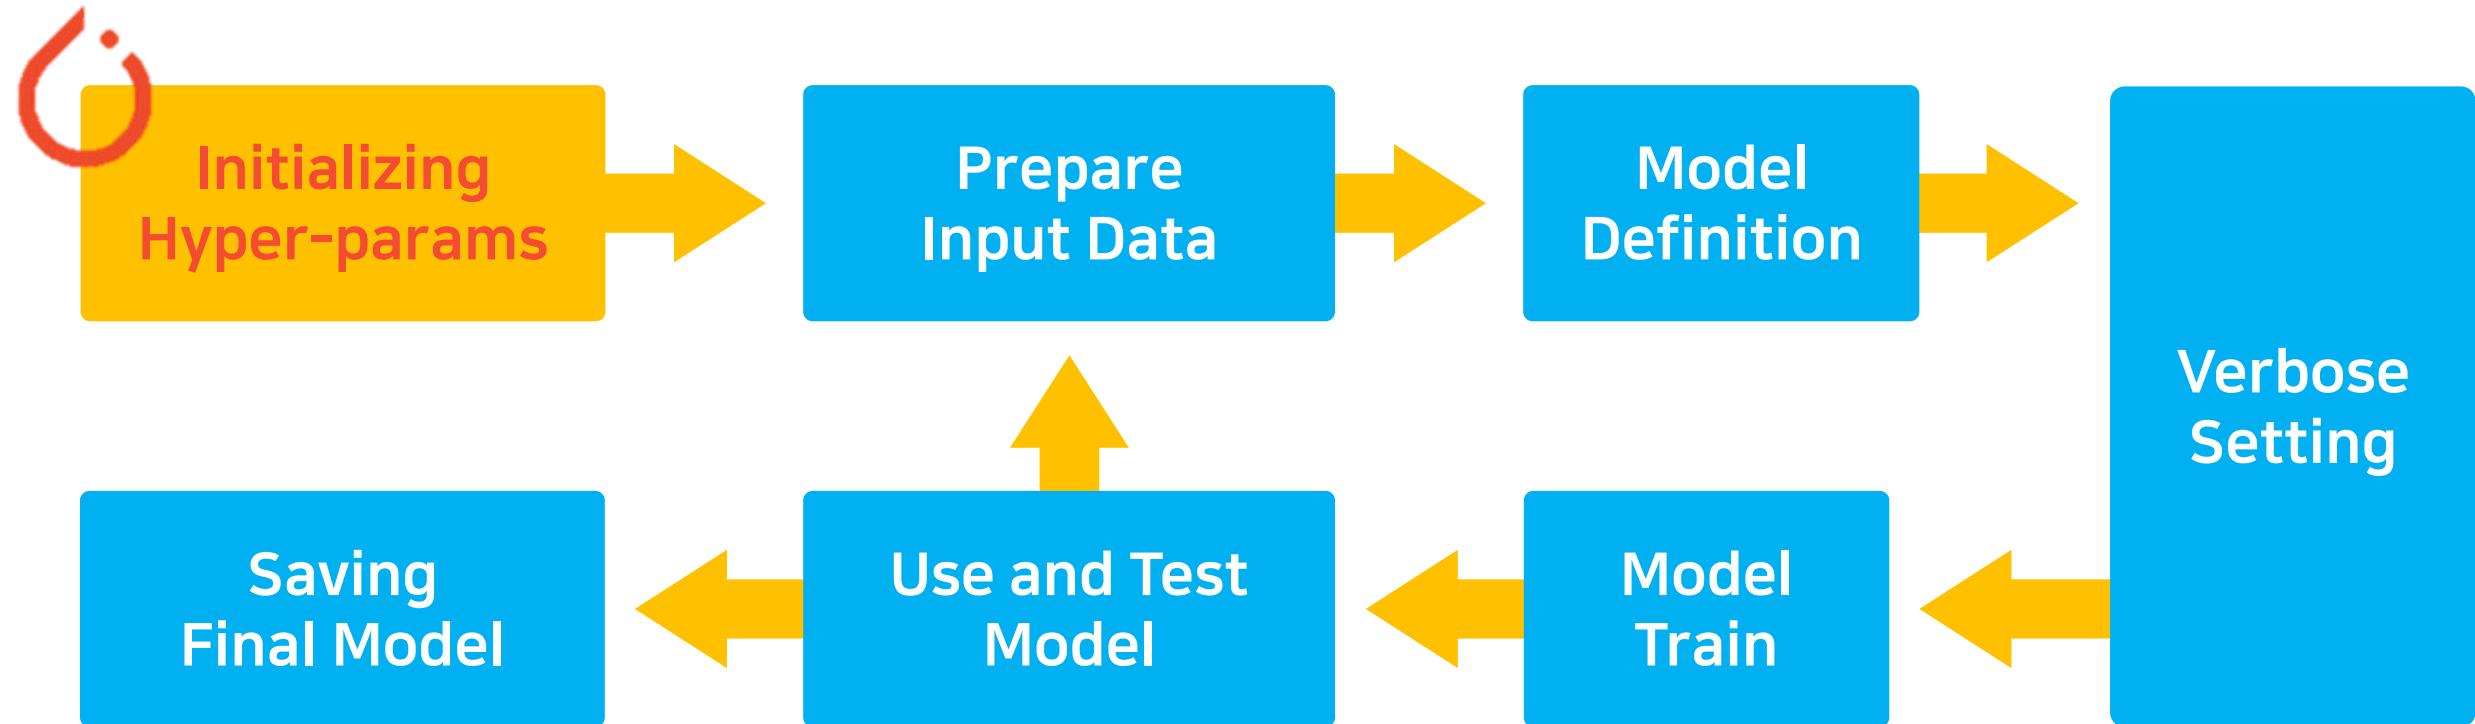
```
model = Net()
```

- 데이터 전처리 시 '데이터 로더' 개념 숙지 필요
- 코드가 비교적 복잡하지만 세부 파라미터 설정에 대한 자유도가 높음
- Verbose 기능 직접 코딩

# PyTorch Framework Flow

PIAI Research Department

- Deep Learning 모델 구축 과정



# HyperParameter Setting

PIAI Research Department

- 하이퍼 파라미터 설정 - 1

```

1 # 데이터 토더
2 batch_size = 32
3

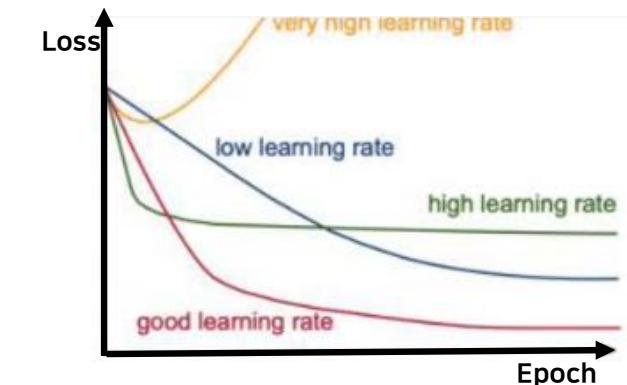
```

- 데이터를 한번에 몇 개를 넣을지
- 전체 데이터셋을 몇 번 학습할지
- 학습하는 속도 조절

```

1 # 최대 에폭
2 maximum_epoch = 10 # 최대 epoch
3 learning_rate = 0.01 # Learning Rate

```



# HyperParameter Setting

PIAI Research Department

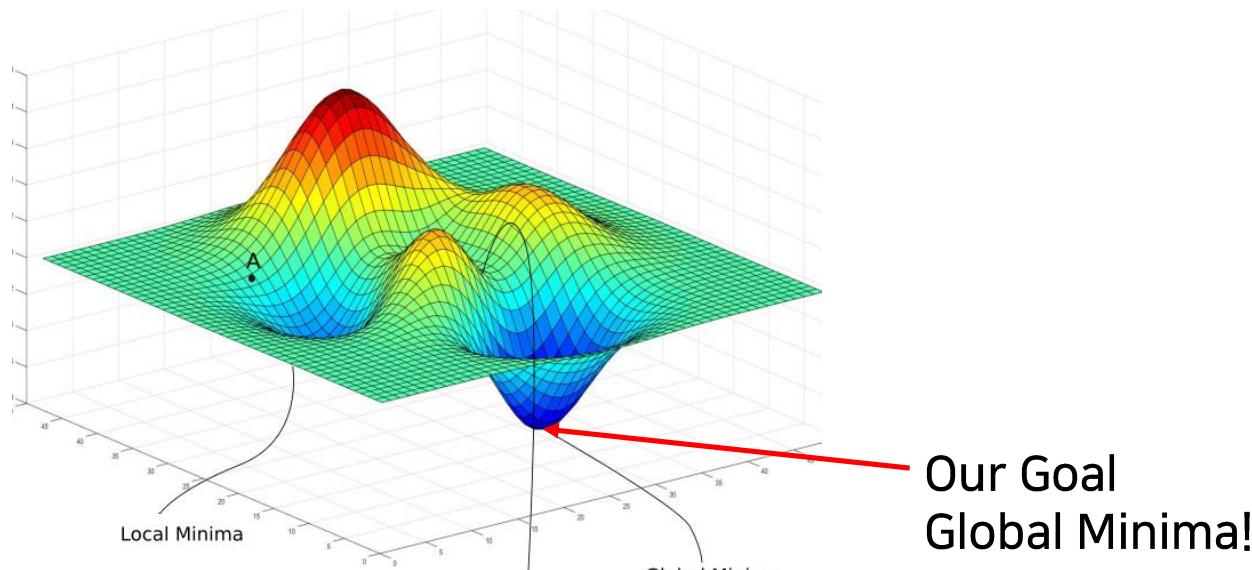
- 하이퍼 파라미터 설정 - 2

```

1 # Model
2 def init_model(_net):
3     global net, loss_fn, optim
4     net = _net.to(device)
5     loss_fn = nn.CrossEntropyLoss()
6     # optim = Adam(net.parameters(), lr=learning_rate)
7     optim = SGD(net.parameters(), lr=learning_rate)

```

- 정답지와 예측값을 비교하여 '모델이 틀린 정도'에 대해서 알아내는 Loss Function
- Gradient Descent를 어떻게 할지에 대해 Optimizer를 지정 (Stochastic Gradient Descent)



# HyperParameter Setting

PIAI Research Department

- PyTorch에서 사용 가능한 Optimizer 종류

<b>Adadelta</b>	Implements Adadelta algorithm.
<b>Adagrad</b>	Implements Adagrad algorithm.
<b>Adam</b>	Implements Adam algorithm.
<b>AdamW</b>	Implements AdamW algorithm.
<b>SparseAdam</b>	Implements lazy version of Adam algorithm suitable for sparse tensors.
<b>Adamax</b>	Implements Adamax algorithm (a variant of Adam based on infinity norm).
<b>ASGD</b>	Implements Averaged Stochastic Gradient Descent.
<b>LBFGS</b>	Implements L-BFGS algorithm, heavily inspired by <code>minFunc</code> .
<b>NAdam</b>	Implements NAdam algorithm.
<b>RAdam</b>	Implements RAdam algorithm.
<b>RMSprop</b>	Implements RMSprop algorithm.
<b>Rprop</b>	Implements the resilient backpropagation algorithm.
<b>SGD</b>	Implements stochastic gradient descent (optionally with momentum).

# HyperParameter Setting

PIAI Research Department

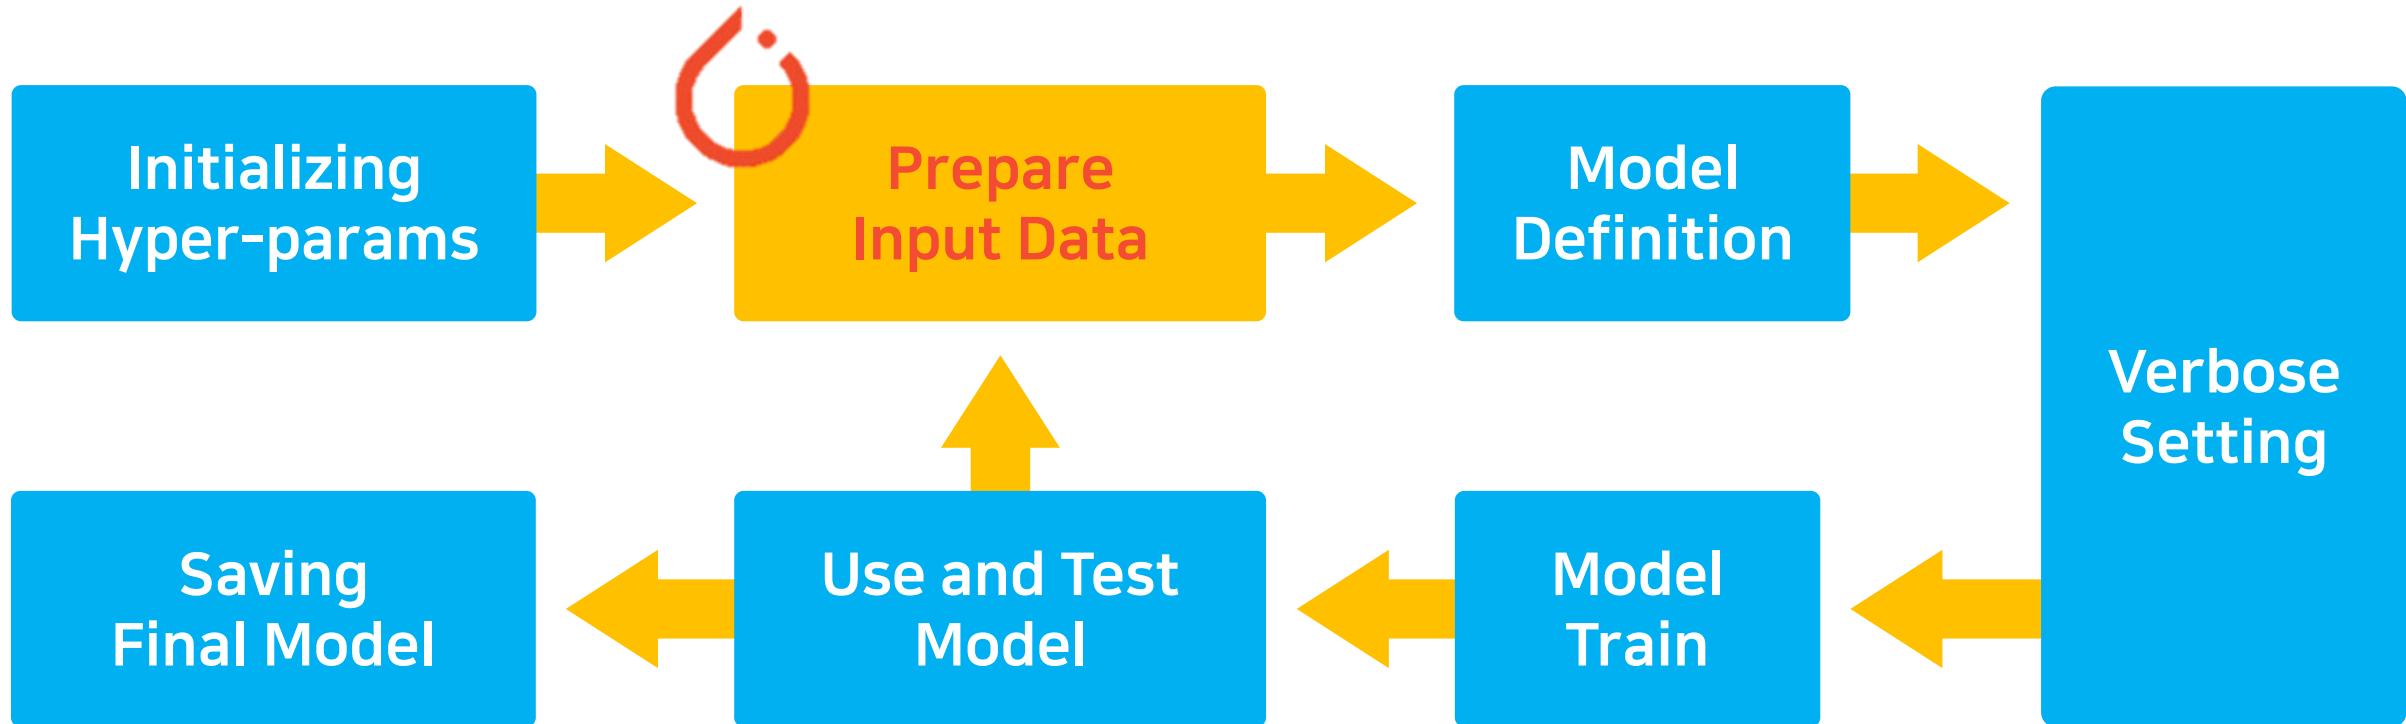
- PyTorch에서 사용 가능한 Loss Function 종류



# PyTorch Framework Flow

PIAI Research Department

- Deep Learning 모델 구축 과정



# Dataset Preparation

PIAI Research Department

- 데이터셋 Tensor 변환 & 전처리

```
1 mnist_transform = transforms.Compose([transforms.ToTensor(), transforms.Normalize(mean=(0.5,), std=(1.0,))])
```

텐서(Tensor)라고 하면 텐서플로우를 떠올리기 쉽지만, 사실 딥러닝에서는 데이터를 처리하기 위한 데이터의 형태라고 이해하면 된다.

```
In [355]: 1 a = [1, 2, 3], [4, 5, 6]
In [356]: 1 print(a)
           ([1, 2, 3], [4, 5, 6])
In [357]: 1 a = torch.tensor(a)
           2 print(a)
           tensor([[1, 2, 3],
           [4, 5, 6]])
```

- Transform 옵션에서 텐서화, 정규화, 데이터 어그멘테이션 등 데이터 전처리에 대한 여러가지 옵션 제공
- 딥러닝 학습을 위해서는, Tensor 형식으로 변환해주어야 PyTorch에서 처리 가능

# Dataset Preparation

PIAI Research Department

- 전처리된 데이터셋을 DataLoader에 업로드

```

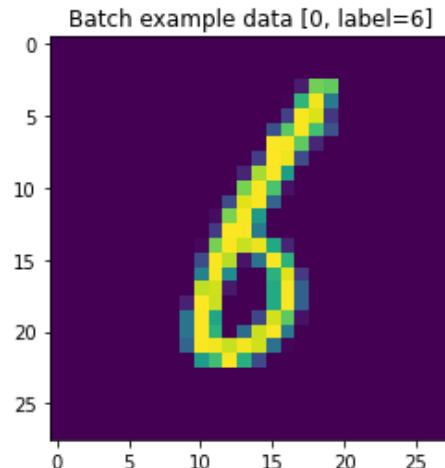
1 # Train / Validation / Test 셋에 대한 데이터 로더 만들기
2 train_loader = DataLoader(train_data, batch_size=batch_size, shuffle=True, pin_memory=True, drop_last=True)
3 valid_loader = DataLoader(valid_data, batch_size=len(valid_data), pin_memory=True)
4 test_loader = DataLoader(test_data, batch_size=len(test_data), pin_memory=True)
5

```

```

Idx: 0 / X.shape = torch.Size([32, 1, 28, 28]) / Y.shape = torch.Size([32])
Y[0:32] = tensor([6, 0, 8, 5, 5, 2, 6, 3, 3, 7, 4, 6, 2, 4, 8, 1, 8, 6, 7, 8, 2, 6, 8, 9,
                  9, 1, 8, 3, 7, 9, 5, 1])

```



# 데이터 로더  
batch\_size = 32

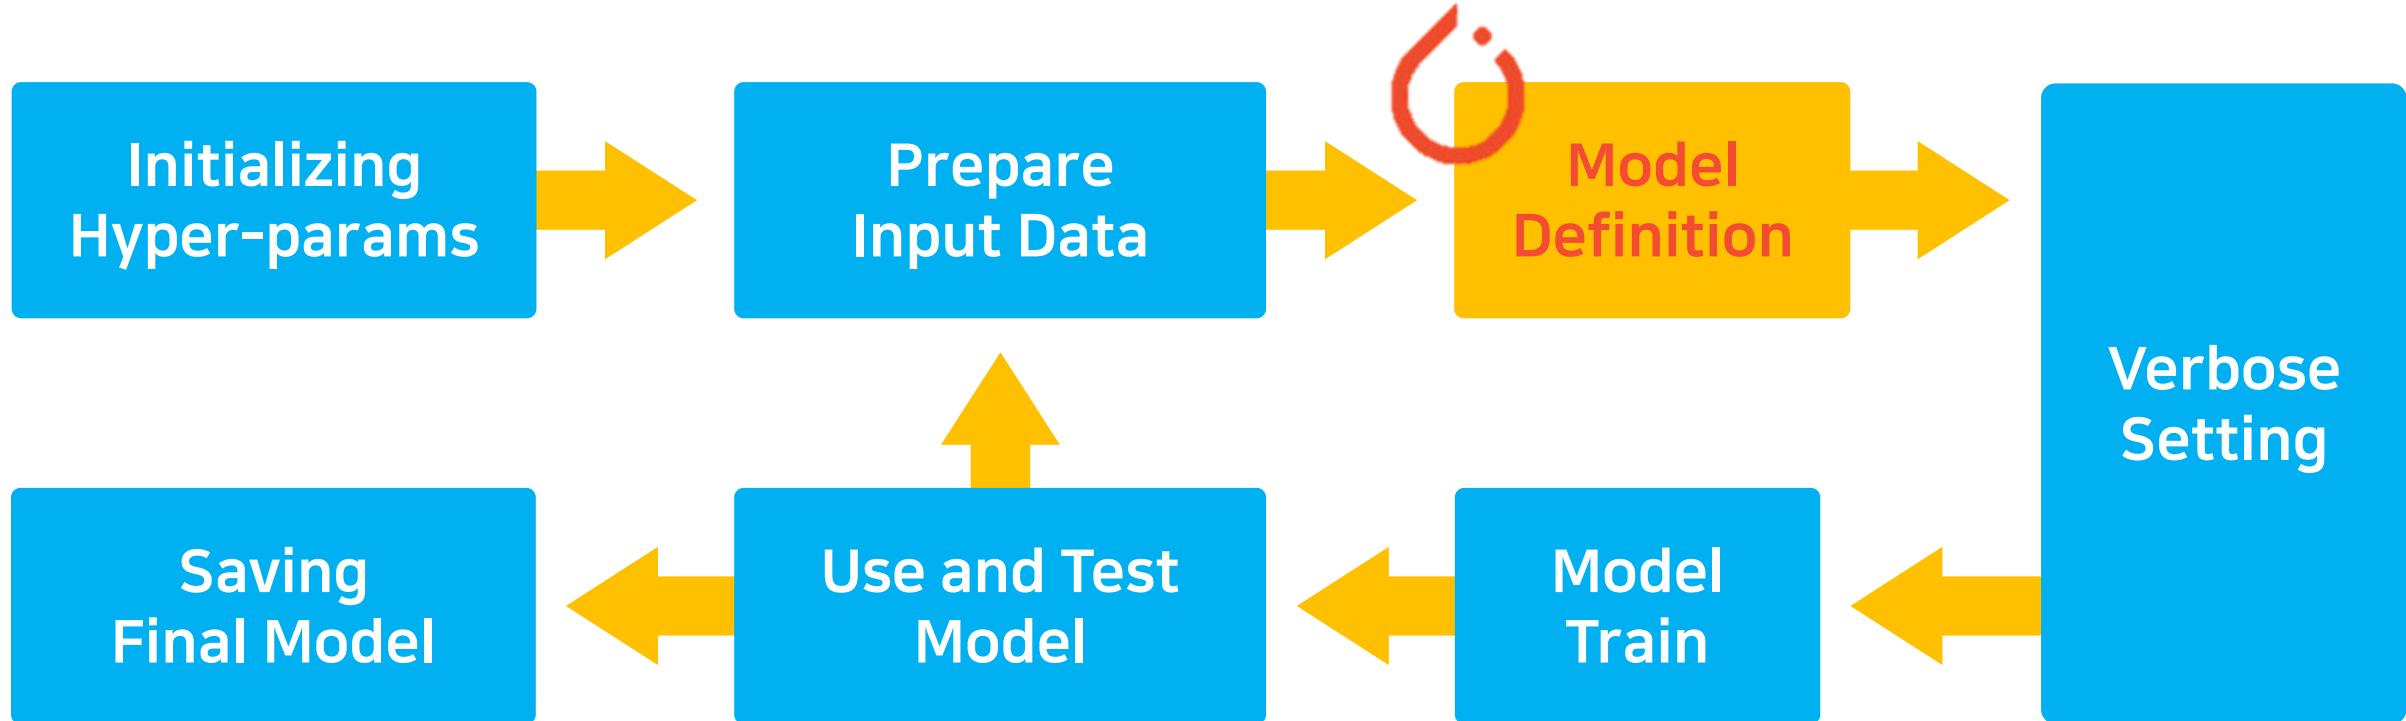
- 전처리된 데이터를 DataLoader에 추가

- DataLoader 출력시, Batchsize에 맞게 구성되어 있음을 확인

# PyTorch Framework Flow

PIAI Research Department

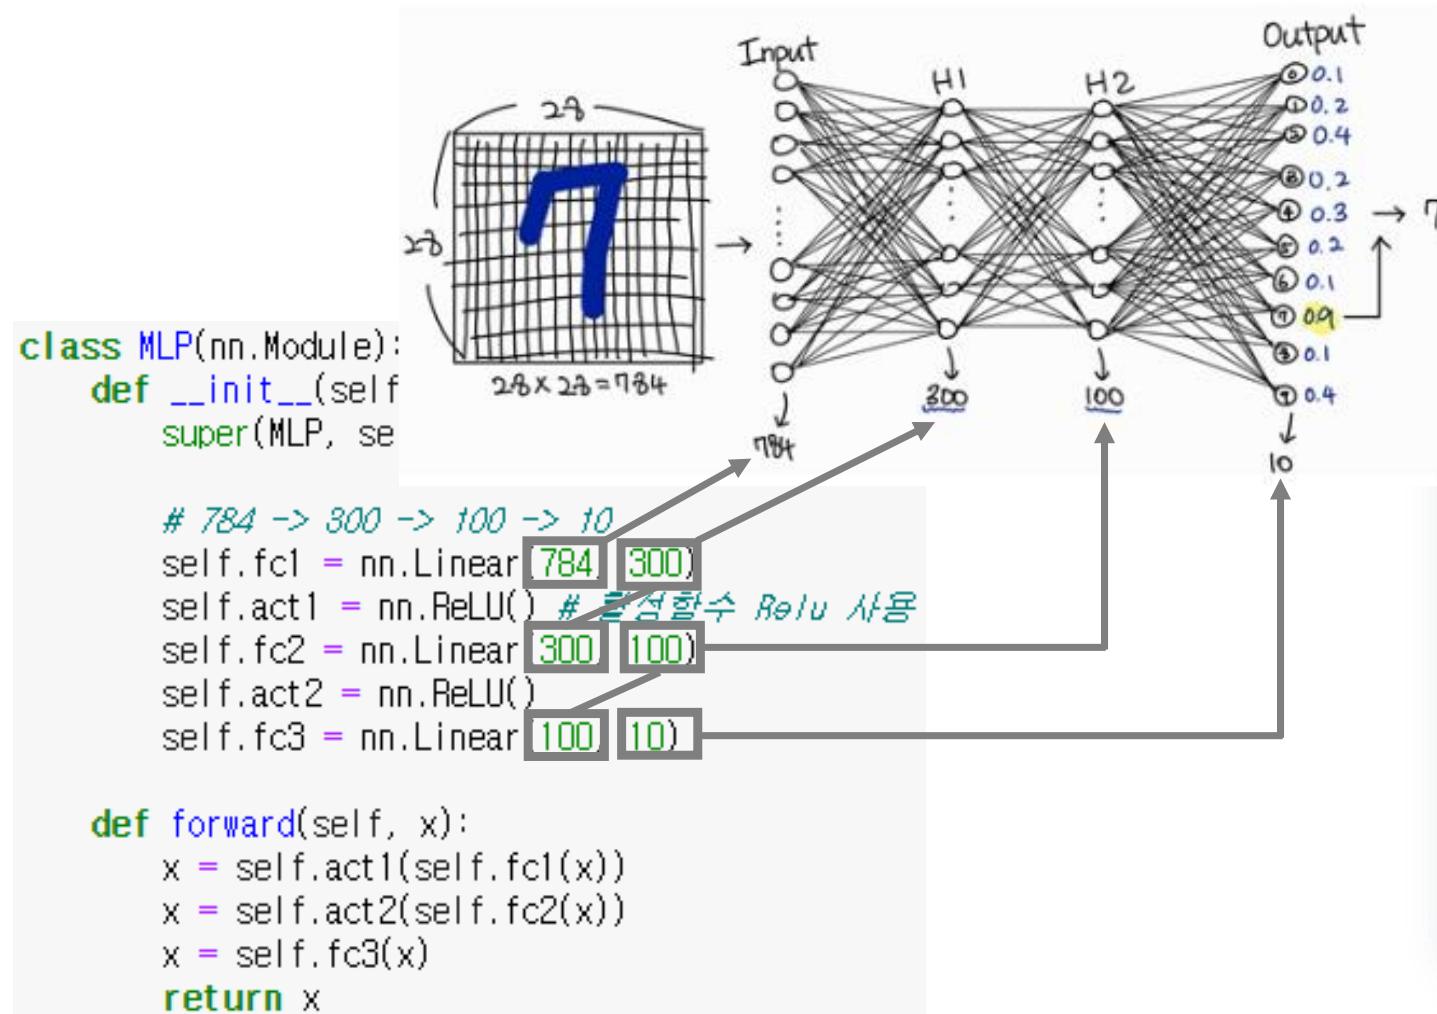
- Deep Learning 모델 구축 과정



# Network Architecture Design

PIAI Research Department

- 딥러닝 모델 구조 설계



- MLP(Multi Layer Perceptron) 모델 구조 설계
  - 1)  $28 * 28$ 의 pixel로 구성된 사진을 784개의 뉴런으로 입력
  - 2) 입력단과 출력단 사이에 HL 추가 (정확도 ↑ but 연산량 ↑)
  - 3) 히든 레이어에는 Activation Func.으로 ReLU 사용
  - 4) 입력을 0 ~ 9 中 하나로 분류하기 위하여 10개의 class로 결과 표출

# Training Algorithm Setting

PIAI Research Department

```

def epoch(data_loader):
    global epoch_cnt
    iter_loss, iter_acc = [], []
    last_grad_performed = False

    # Mini-batch iterations
    for _data, _label in data_loader:
        data, label = _data.view([len(_data), -1]).tc

        # 1. Feed-forward
        result = net(data)
        _, out = torch.max(result, 1)

        # 2. Calculate loss
        loss = loss_fn(result, label)
        iter_loss.append(loss.item())

        # 3. Backward propagation(train mode에서만)
        if result.requires_grad:
            optim.zero_grad()
            loss.backward()
            optim.step()
            last_grad_performed = True

        # 4. Calculate accuracy
        acc_partial = (out == label).float().sum()
        acc_partial = acc_partial / len(label)
        iter_acc.append(acc_partial.item())
    
```

Validation/Test 경우 `torch.no_grad()`  
 를 사용하여 if문을 만족 -> 학습 안함

```

with torch.no_grad():
    vloss, vacc = epoch(valid_loader)

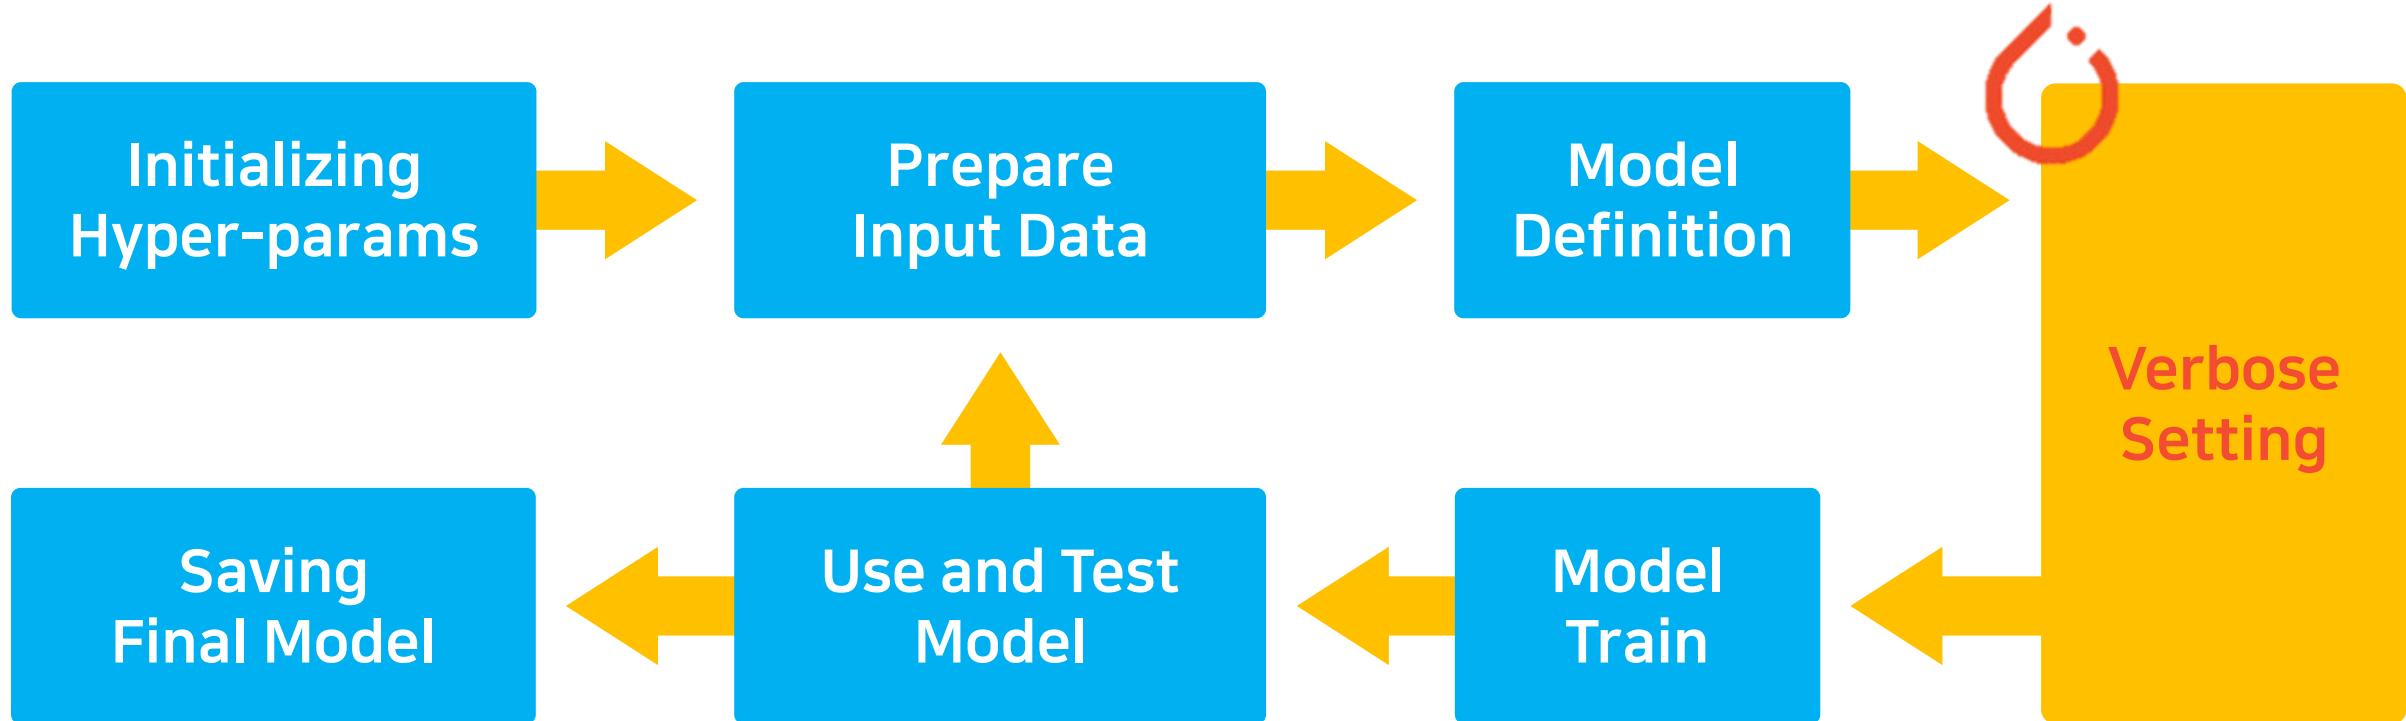
```

- 모델이 Loss를 줄이는 방향으로 학습하도록 알고리즘 구축
- 1) 모델에 데이터 투입
- 2) 정답지와 결과를 비교하여 Loss 산정(Loss Function 사용)
- 3) Loss를 줄이기 위하여 Back Propagation시행(Train 에서만)
- 4) 1 Step 만큼 Gradient Decent 진행(Learning Rate만큼 Activation Function으로 하강)
- 5) 1 ~ 4번을 Epochs 만큼 반복

# PyTorch Framework Flow

PIAI Research Department

- Deep Learning 모델 구축 과정



# Verbose Setting

PIAI Research Department

- Verbose(학습 Log 출력 여부) 설정

```

def record_train_log(_tloss, _tacc, _time):
    # Train Log를 추가해준다
    time_log.append(_time)
    tloss_log.append(_tloss)
    tacc_log.append(_tacc)
    iter_log.append(epoch_cnt)

def record_valid_log(_vloss, _vacc):
    # Validation Log를 추가해준다
    vloss_log.append(_vloss)
    vacc_log.append(_vacc)

def print_log():
    # 로그 프린트

    # 소숫점 3자리 수까지 조절
    train_loss = round(last(tloss_log), 3)
    train_acc = round(last(tacc_log), 3)
    val_loss = round(last(vloss_log), 3)
    val_acc = round(last(vacc_log), 3)
    time_spent = round(last(time_log), 3)

    log_str = 'Epoch: {:3} | T_Loss {:5} | T_acc {:5} | V_Loss {:5} | V_acc. {:5} | #{:5}'.format(last(iter_log), train_loss, train_acc, val_loss, val_acc, time_spent)

    log_stack.append(log_str) # 프린트할 리스트에 추가
    clear_output(wait=True) # 출력을 모두 초기화

    for log_print in log_stack:
        print(log_print) # 각각마다 추이를 출력

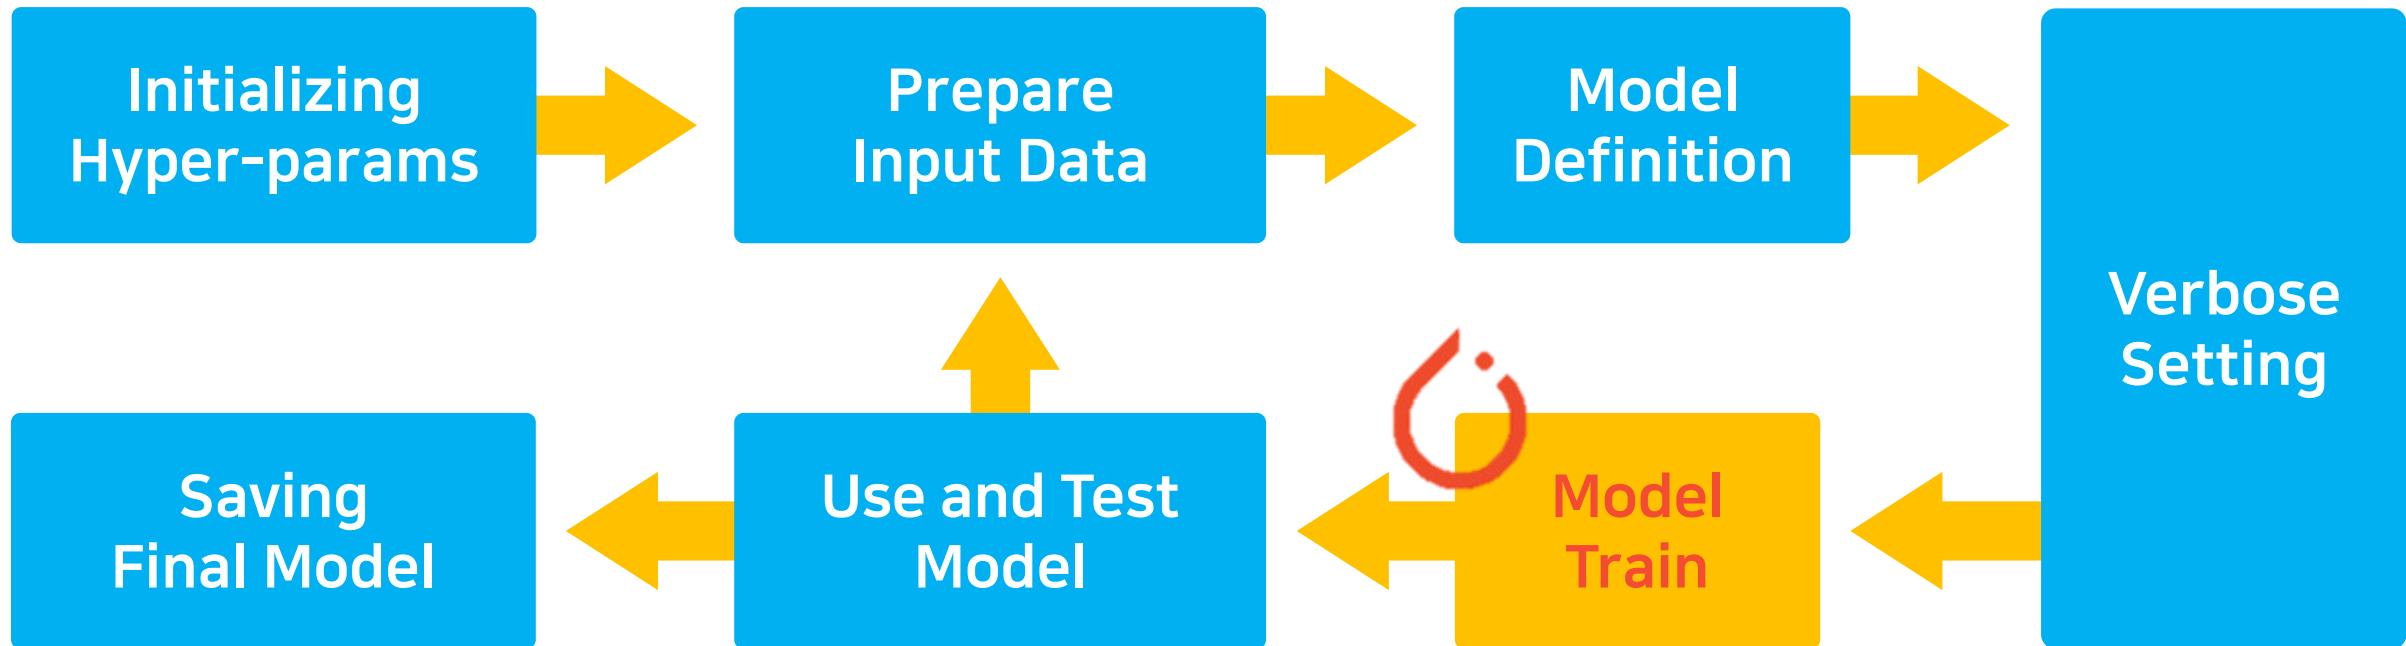
```

- 모델이 학습되는 동안의 실시간 추이를 볼 수 있도록 알고리즘 구축
- Train과 Validation의 Loss와 Acc.를 기록하는 기능
- 매 Epoch마다 추이를 출력

# PyTorch Framework Flow

PIAI Research Department

- Deep Learning 모델 구축 과정



# Model Training

PIAI Research Department

- 딥러닝 모델 학습

```

1 # Training Initialization
2 init_model(ANN(784, 10))
3 init_epoch()
4 init_log()
5 losses_train, losses_val = [], []
6
7 # Training Iteration
8 while epoch_not_finished():
9     start_time = time.time()
10
11     tloss, tacc = epoch(train_loader)
12
13     losses_train.append(tloss)
14     end_time = time.time()
15     time_taken = end_time - start_time
16     record_train_log(tloss, tacc, time_taken)
17
18     with torch.no_grad():
19         vloss, vacc = epoch(valid_loader)
20
21         losses_val.append(vloss)
22         record_valid_log(vloss, vacc)
23
24     print_log()
25
26 print('Training completed!')

```

Verbose  
함수

- 설계한 모델과 학습 알고리즘을 불러와 학습 진행
- 모델, Epoch 카운터, 로깅 관련 변수들 초기화
- 설정한 Epoch 수만큼 while(for)문을 돌면서 train 반복
- Train 파트
- Validation 파트  
`torch.no_grad()` = 역전파 학습을 하지 않는다
- Verbose(학습 추이) 출력

# Model Training

PIAI Research Department

- 딥러닝 모델의 학습 추이 출력

```
20 print_log() # 로그를 프린트
21
22 print('Training completed!')
```

Epoch:	1	T_Loss	1.159	T_acc	0.704	V_Loss	0.47	V_acc.	0.869	⌚	14.727
Epoch:	2	T_Loss	0.393	T_acc	0.887	V_Loss	0.354	V_acc.	0.897	⌚	15.019
Epoch:	3	T_Loss	0.325	T_acc	0.905	V_Loss	0.313	V_acc.	0.91	⌚	13.68
Epoch:	4	T_Loss	0.289	T_acc	0.915	V_Loss	0.283	V_acc.	0.915	⌚	14.157
Epoch:	5	T_Loss	0.26	T_acc	0.924	V_Loss	0.272	V_acc.	0.919	⌚	14.035
Epoch:	6	T_Loss	0.236	T_acc	0.931	V_Loss	0.241	V_acc.	0.93	⌚	14.326
Epoch:	7	T_Loss	0.214	T_acc	0.938	V_Loss	0.223	V_acc.	0.934	⌚	14.606
Epoch:	8	T_Loss	0.194	T_acc	0.943	V_Loss	0.205	V_acc.	0.938	⌚	15.849
Epoch:	9	T_Loss	0.178	T_acc	0.947	V_Loss	0.191	V_acc.	0.941	⌚	13.956
Epoch:	10	T_Loss	0.163	T_acc	0.953	V_Loss	0.18	V_acc.	0.944	⌚	13.761

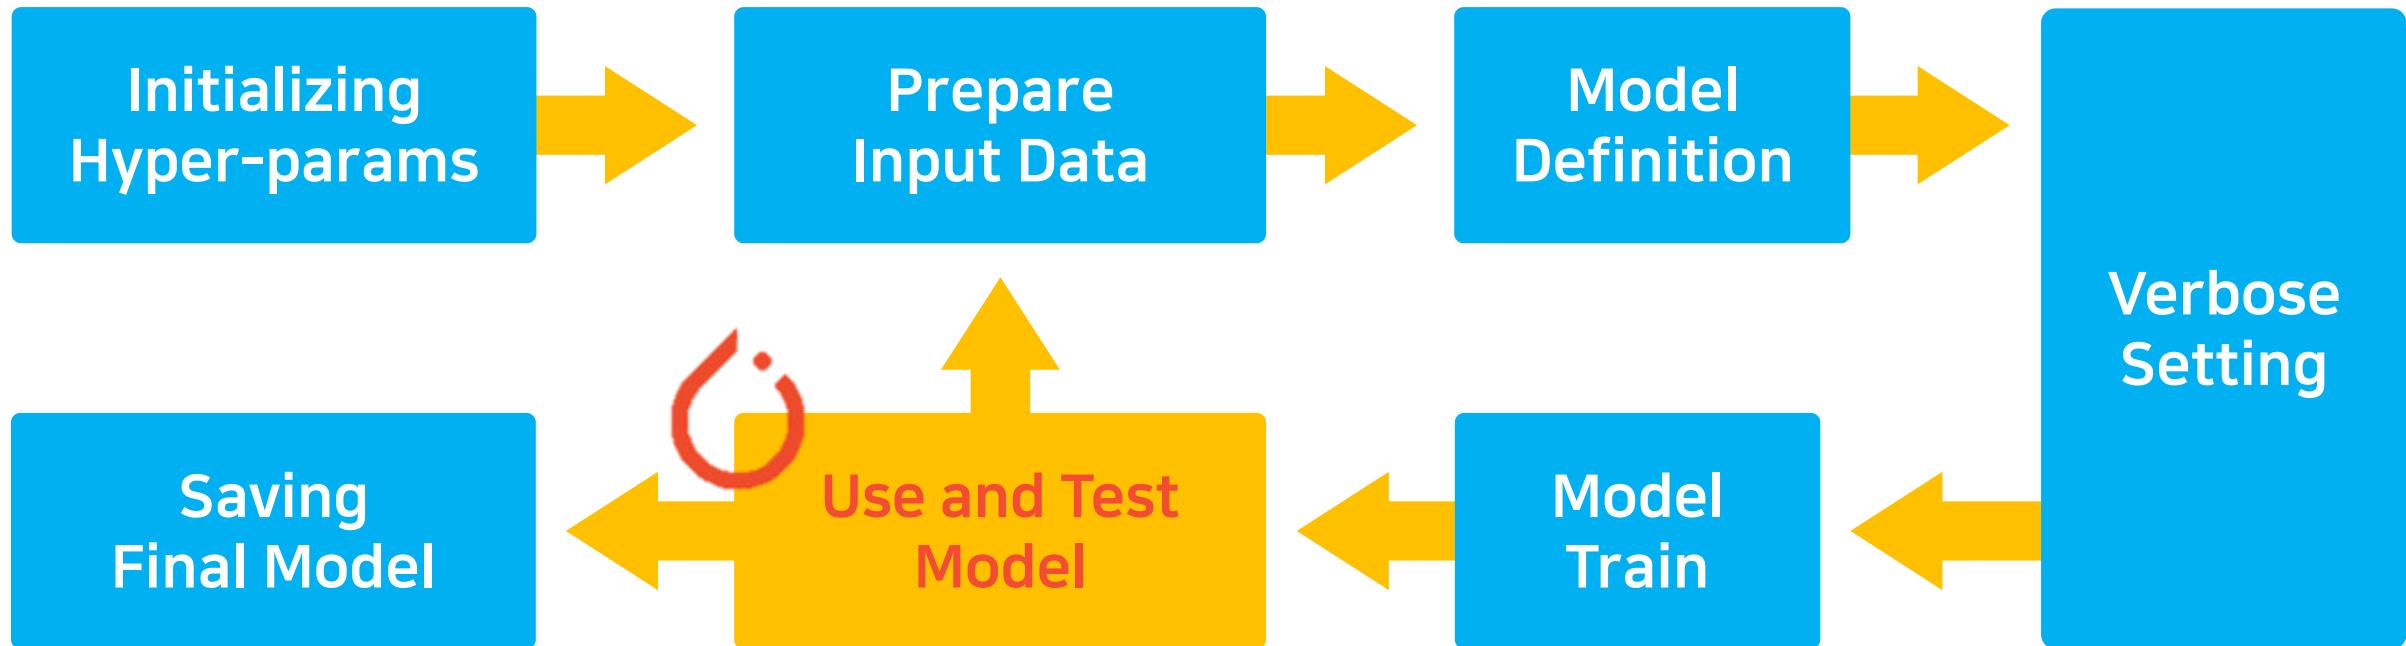
Training completed!

- 각 epoch에 따라 로그를 출력
  - 1) Train Loss
  - 2) Train Acc.
  - 3) Validation Loss
  - 4) Validation Acc.
  - 5) 학습 소요 시간

# PyTorch Framework Flow

PIAI Research Department

- Deep Learning 모델 구축 과정



# Model Testing

PIAI Research Department

- 딥러닝 모델 정확도 산정

```

24 # 정확도 검증
25 with torch.no_grad():
26     test_loss, test_acc = epoch(test_loader)
27     test_acc = round(test_acc, 4)
28     test_loss = round(test_loss, 4)
29     print('Test Acc.: {}'.format(test_acc))
30     print('Test Loss: {}'.format(test_loss))

```

Training completed!

Test Acc.: 0.952

Test Loss: 0.1617

You can install TorchMetrics using pip or conda:

```

# Python Package Index (PyPI)
pip install torchmetrics
# Conda
conda install -c conda-forge torchmetrics

```

- 학습 완료 후 Test데이터 10,000장을 모델에 넣고 분류 (torch.no\_grad() = 역전파 학습 off)
- 모델이 분류한 결과와 Ground Truth값을 비교하여 모델의 정확도 (Acc.) 산출
- PyTorch의 torchmetrics 기능을 통하여 다양한 평가 Metric 사용 가능

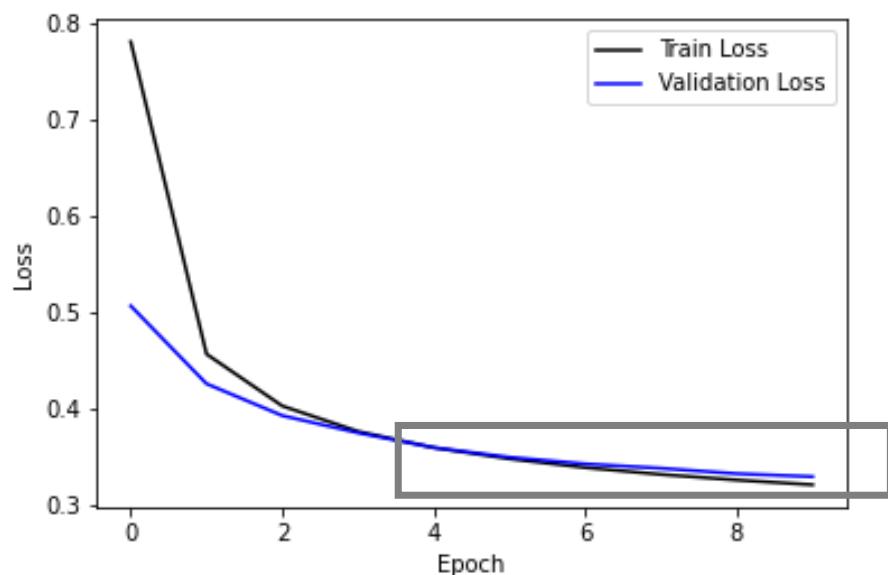
# Model Testing Visualization

PIAI Research Department

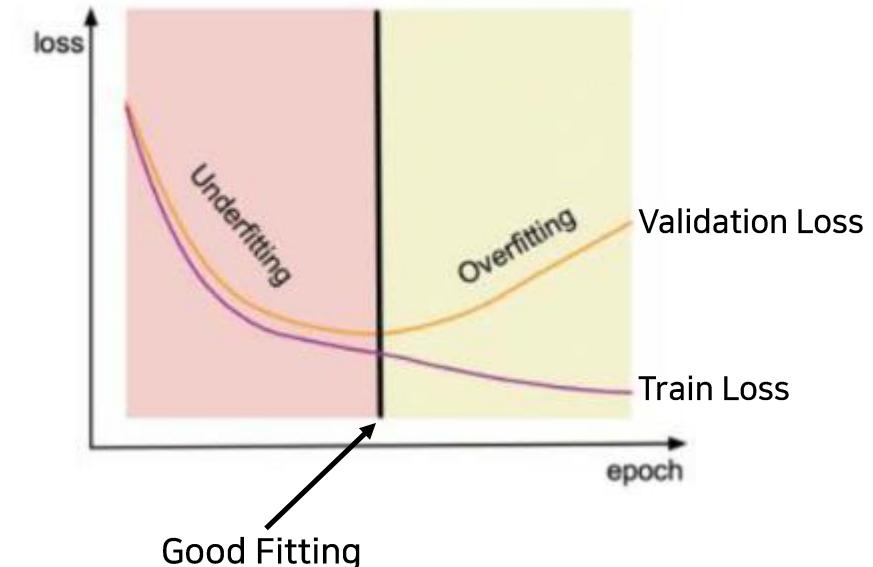
- 모델의 학습 추이를 그래프로 확인

```

1 plt.plot(range(0, maximum_epoch, 1), losses_train, label = 'Train Loss')
2 plt.plot(range(0, maximum_epoch, 1), losses_val, label = 'Validation Loss')
3 plt.legend(loc = 'upper right')
4 plt.ylabel('Loss')
5 plt.xlabel('Epoch')
6 plt.show()
    
```



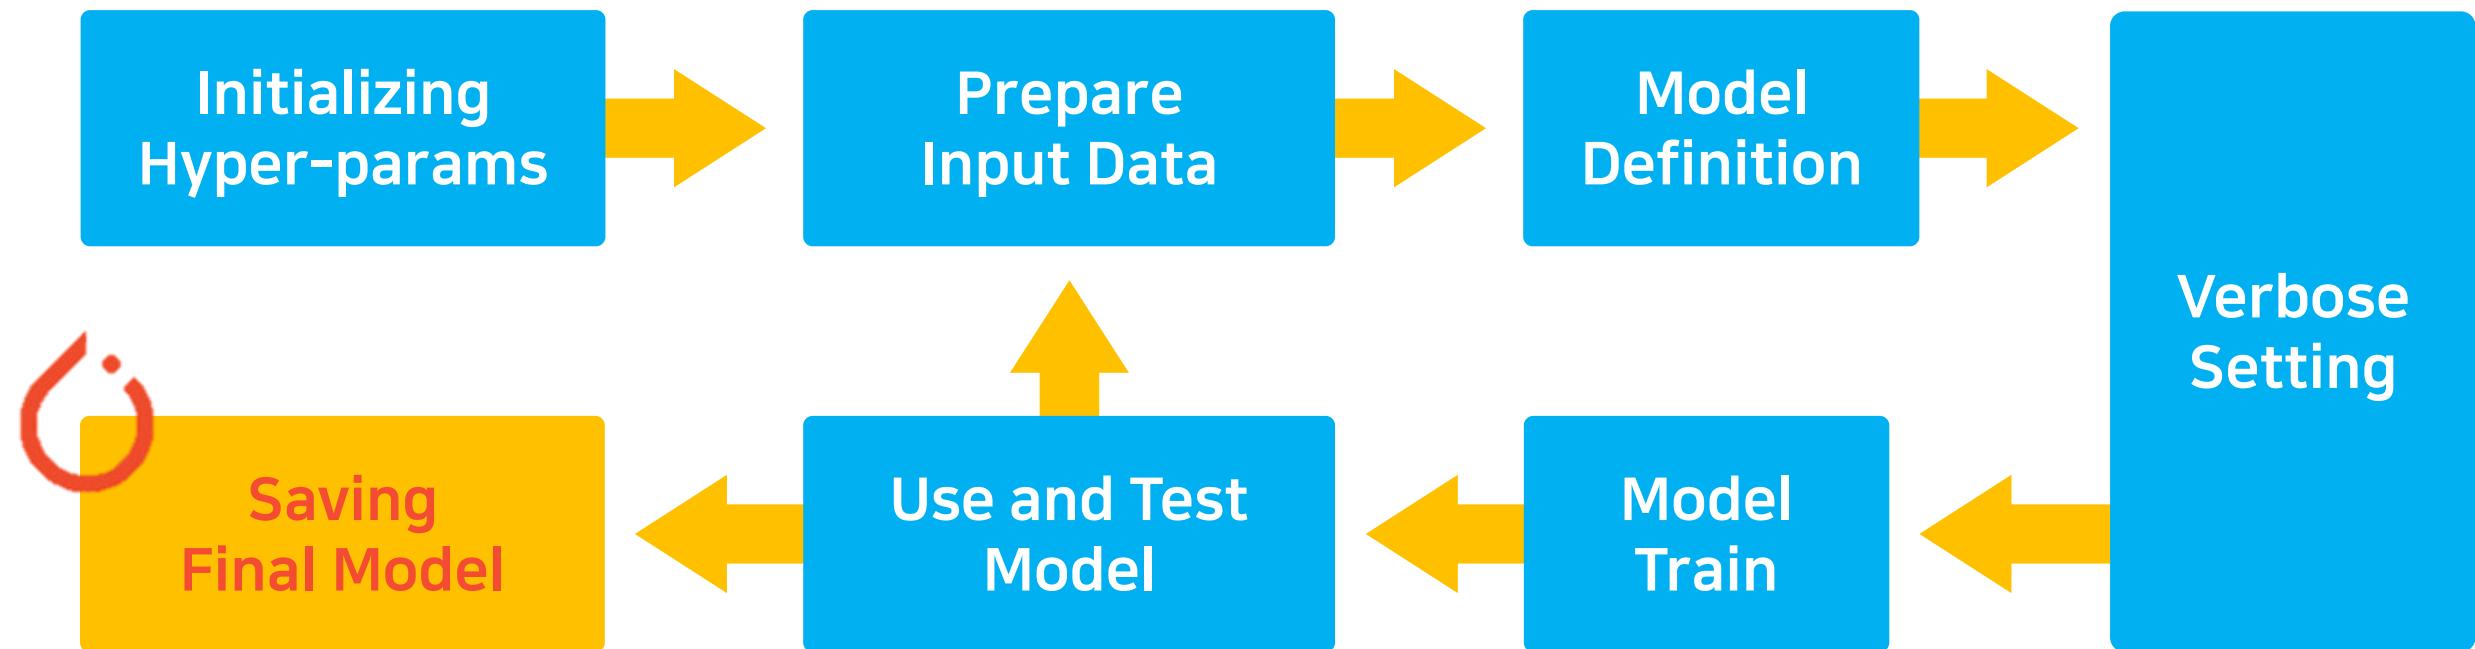
- 학습 중 진행된 epoch에 따라 감소되는 Loss의 추이를 시각화
- Loss가 계속 줄어들고 있는 그래프 추이로 보아, 추가 학습 가능



# PyTorch Framework Flow

PIAI Research Department

- Deep Learning 모델 구축 과정



# Model Saving/Loading

PIAI Research Department

## • 모델 저장 / 로드

```
1 torch.save(net.state_dict(), './model.pth')  
2  
3 net = MLP(in_features = 784, out_features = 10).to(device)  
4  
5 net.load_state_dict(torch.load('./model.pth'))  
<All keys matched successfully>
```

- 학습된 모델을 저장하여, 필요시 로드하여 사용 가능
- 저장할 경로를 지정하여 모델을 .pth 포맷으로 저장
- 저장한 모델을 로드하기 위하여, 비어 있는 모델을 선언(입 출력 개수)
- 선언한 모델에, 저장되어 있는 모델의 경로를 입력하여 로드 후 사용

# Code Running

**(student) 1\_Pytorch Basic & Classifier.ipynb**