



Machine Learning Analysis Feature Extraction

GyeongYeong, Kim



- **Keras Model Analysis**

- Callback
- History Confirmation
- Wrong Sample Confirmation
- Confusion Matrix

- **Feature Extraction**

- CNN / Pooling Layer
- Batch Normalization / DropOut

- **Pytorch Feature Extraction**

- CNN / Pooling Layer
- Batch Normalization / DropOut
- Best Model Saving
- History Confirmation
- Confusion Matrix
- Wrong Sample Confirmation
- Early Stopping

- Keras Callbacks : 학습 이슈를 분석하거나 조정할 때 쓰이는 학습 보조기능

ModelCheckpoint : 학습 도중 모델 저장

TerminateOnNaN : NaN 손실이 발생했을 때 학습을 종료

RemoteMonitor : 이벤트를 서버에 스트림

LearningRateScheduler : 학습속도에 대해 스케줄을 짤

EarlyStopping : 학습 양상을 보고 학습을 조기에 종료(Overfitting 방지)

Tensorboard : 텐서보드로 그래프를 확인할 수 있도록 학습 양상을 기록(동적 그래프나 활성화 히스토그램 시각화)

ReduceLROnPlateau : 측정 항목이 향상되지 않는 경우 학습속도를 줄임

Model Checkpoint

PIAI Research Department

Model Checkpoint : 케라스의 모델(혹은 weight)를 규칙에 따라 저장하는 콜백

- file_path : 모델 저장 경로
- monitor(metric) / save_best_only(True/False) : 모니터할 metric 설정 및 이에 따른 높은 성능의 모델을 저장
- mode (auto/min/max) : 모니터할 metric의 최대나 최소 중 선택(acc는 max, loss는 min)
- Initial_value_threshold : 모니터할 최소/최대 기준값
- save_freq(int) : 저장할 주기(epoch 기준으로 설정)
- verbose(0/1/2) : 콜백이 적용될 시 표출할 모드
- (save_weight_only : full model의 저장 대신 weight만 저장)

```
checkpointer = ModelCheckpoint(filepath=model_name_path,
                               monitor='val_accuracy',
                               verbose=0,
                               save_best_only=True)
```

Early Stopping

PIAI Research Department

Keras Callbacks : 학습 이슈를 분석하거나 조정할 때 쓰이는 학습 보조기능

- monitor(metric) : 모니터할 기준
- patience(int) : 학습 개선이 없어 학습을 멈출 최소 epoch 기준
- verbose(0/1/2) : 콜백이 적용될 시 표출할 모드
- mode(auto/min/max) : monitor metric을 결정하는 기준
- baseline : 모니터하는데에 있어서의 베이스라인 값
- restore_best_weights(True/False) : 가장 좋은 성능으로 저장할지 안할지 설정

```
earlystopper = EarlyStopping(monitor='val_accuracy',  
                             patience=5,  
                             verbose=0,  
                             mode='auto')
```

- Keras Callbacks 중 하나 : 시각화 도구로 활용됨

```
tb_saver = TensorBoard(log_dir=tensorboard_path,  
                        write_graph=True)
```

- 실시간 업데이트 확인 가능 : Time Series 탭 내 Settings로 확인

Fit to screen
Download PNG

Run (1)
Session runs (0)
Upload Choose File

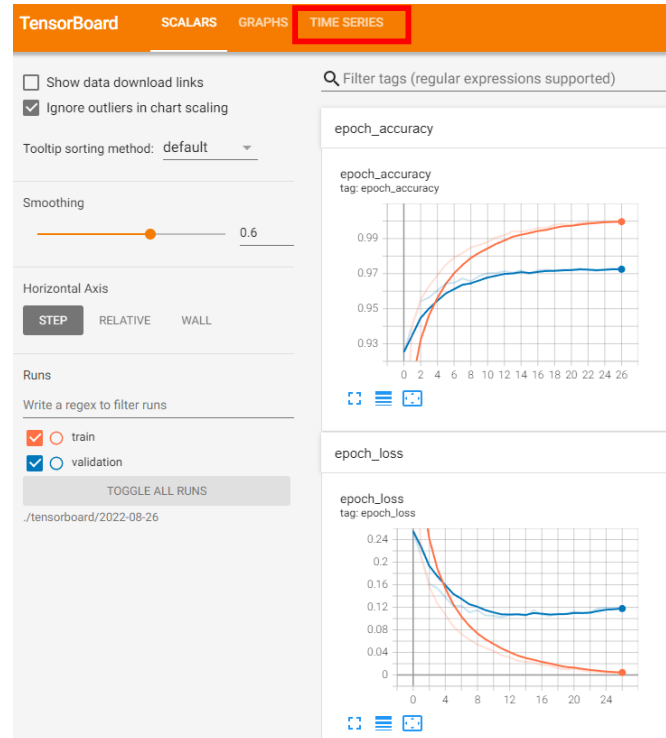

Trace inputs

Color Structure
Device
XLA Cluster
Compute time
Memory
TPU Compatibility

colors same substructure
unique substructure

Close legend.
Graph (* = expandable)

Main Graph



Settings

☒ Reload data


Reload Period

30

Pagination Limit

12


- Epoch 마다의 학습 추이를 확인
- Loss나 Accuracy의 추이를 통해 추가 학습의 필요 여부, Underfitting/ Overfitting 확인



Confusion Matrix

PIAI Research Department

- 모델결과에 대한 분석이 용이함
- 클래스가 많으면 하기에 어려울 수 있음
- 모델의 구체적인 문제 사례를 확인하기엔 한계가 있음 → 특정 사례에 한해 직접 확인!




Wrong Sample 확인


PIAI Research Department

- Confusion Matrix : 거시적 분석 / Wrong Sample : 미시적 분석
- 학습을 통한 개선이 가능한지의 여부를 확인 가능 (항상 네트워크 학습으로 해결할 수 있는 것은 아니다..!)

real_label : 4, predict_label : 9



real_label : 2, predict_label : 7





Feature Extraction

Image classification

PIAI Research Department



```
def classify_image(image):  
    # Some magic here?  
    return class_label
```

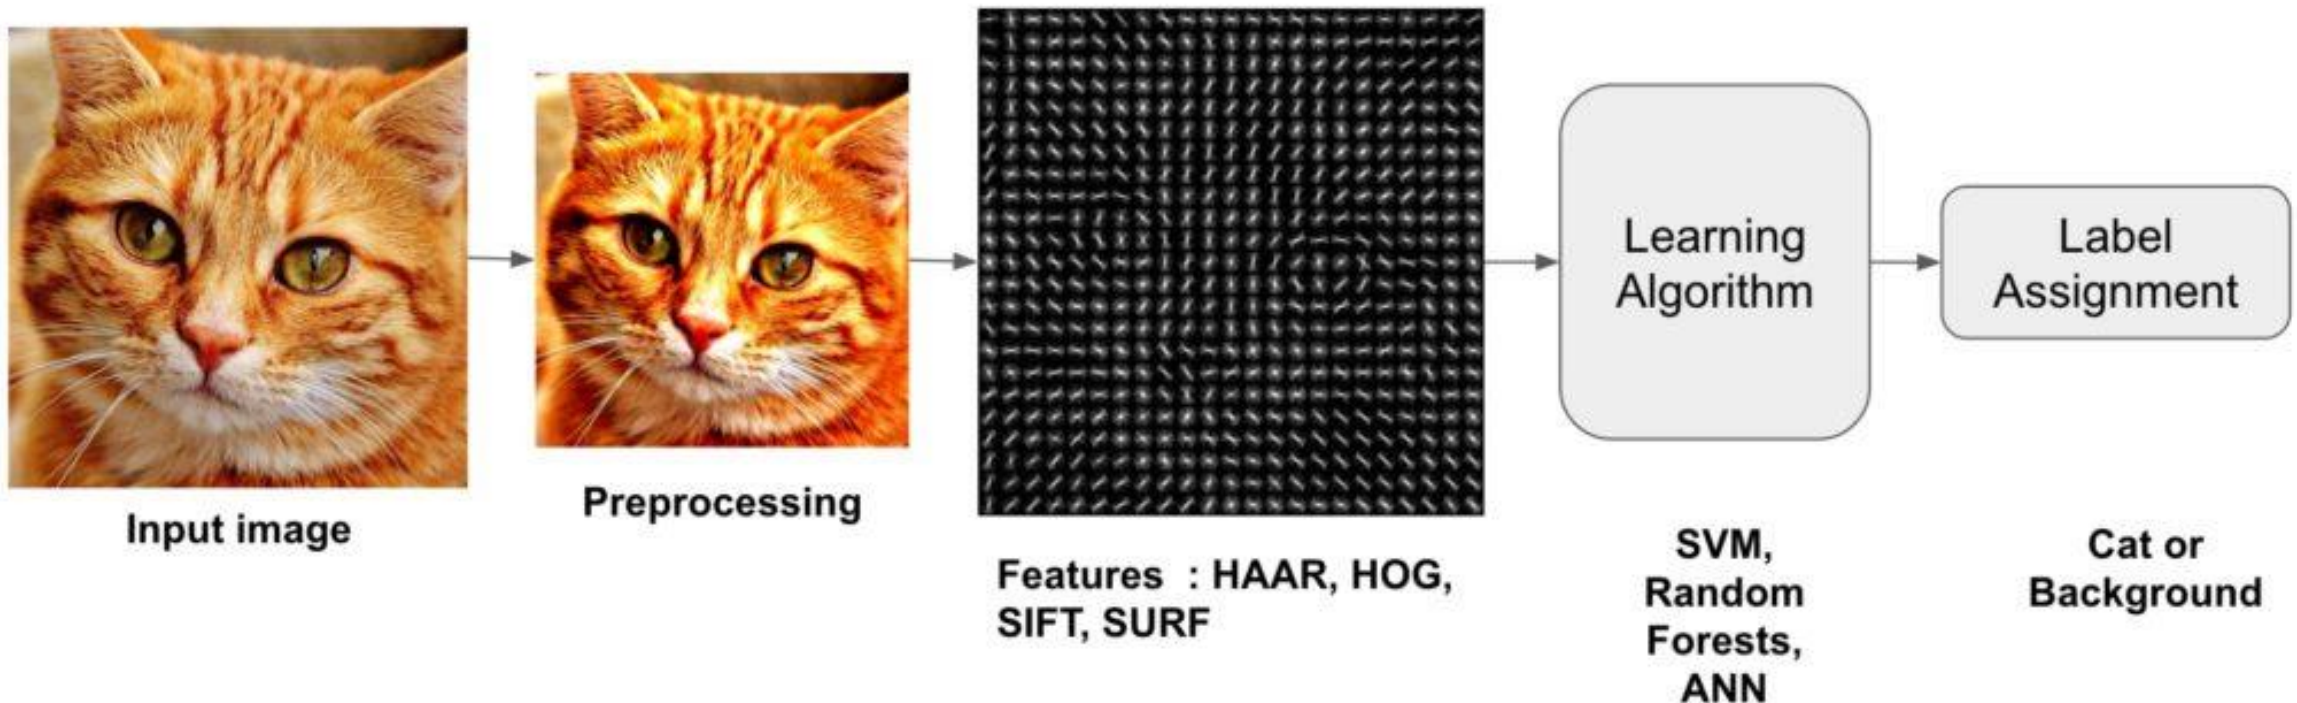
Cat

어떻게 하면 컴퓨터가 '고양이'를 인식하도록 코딩할 수 있을까?

Traditional Image classification

PIAI Research Department

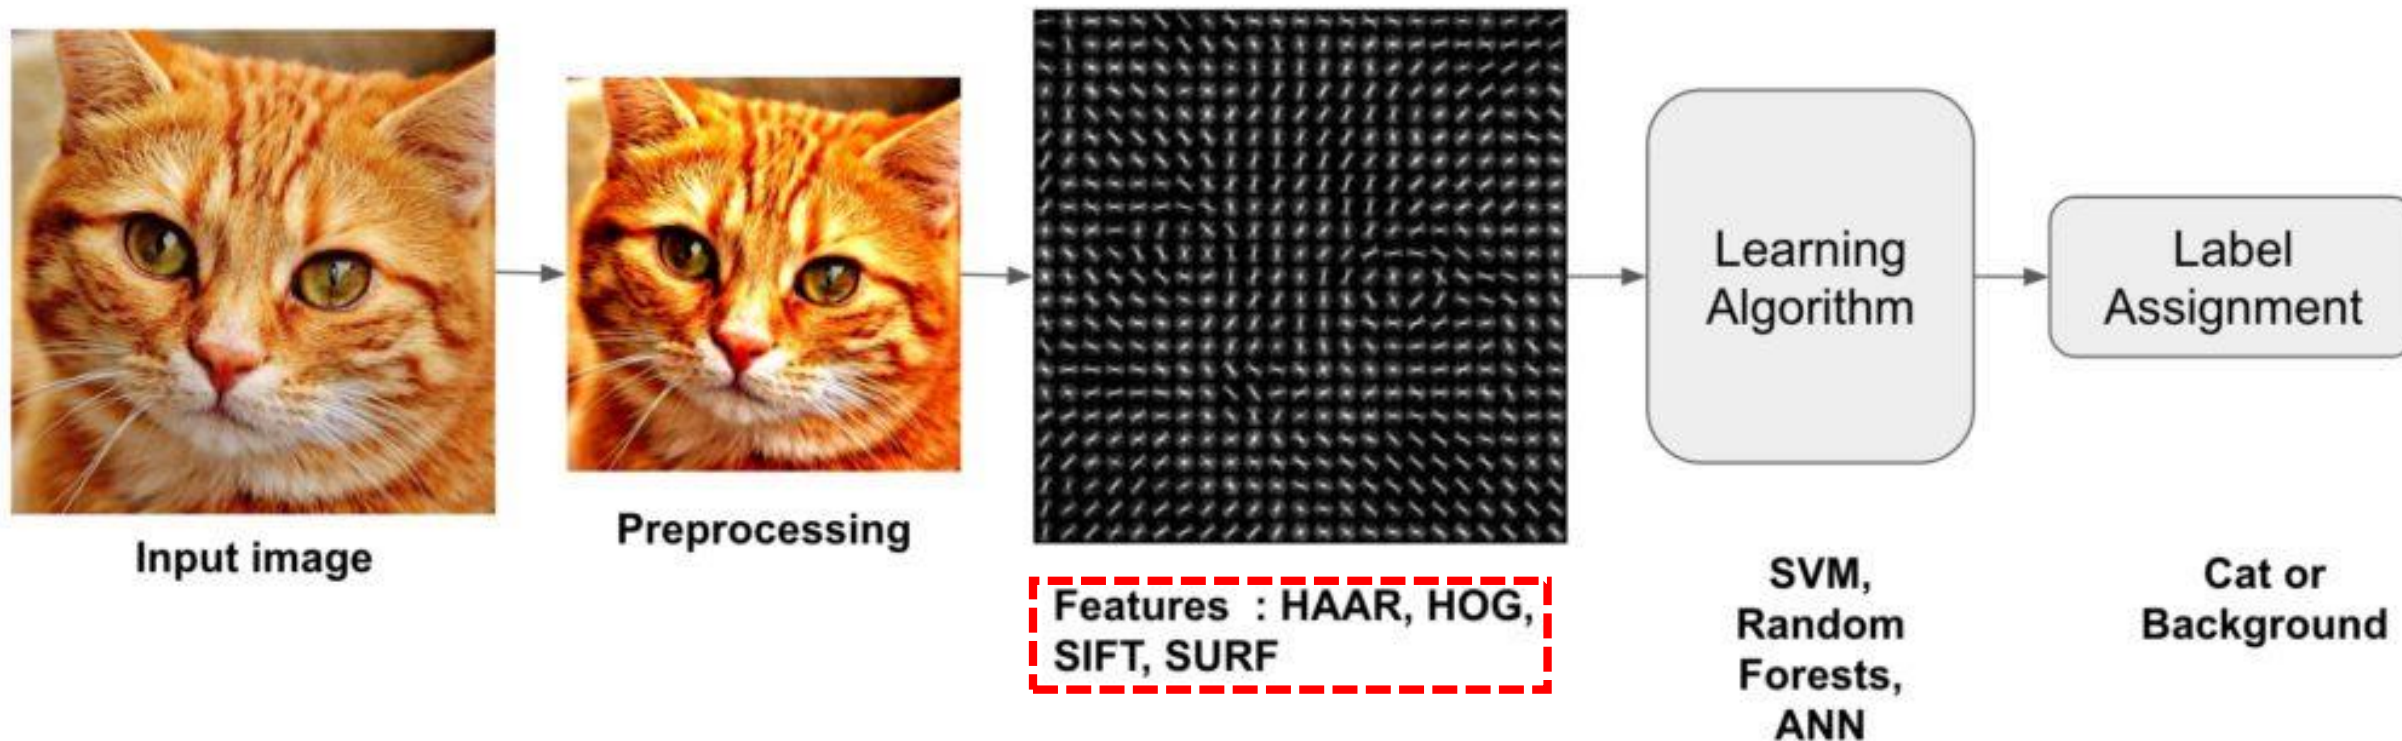
- Traditional Image Classification



Data → Feature extraction → **Classification**

Image classification

PIAI Research Department




Data → **Feature extraction** → Classification
Convolution, max-pooling...

Overall Flow of Deep Learning


PIAI Research Department

- CNN




Fully Connected Layer

PIAI Research Department



Convolution Layer


PIAI Research Department



Convolution Layer

PIAI Research Department

28x28x**1** image



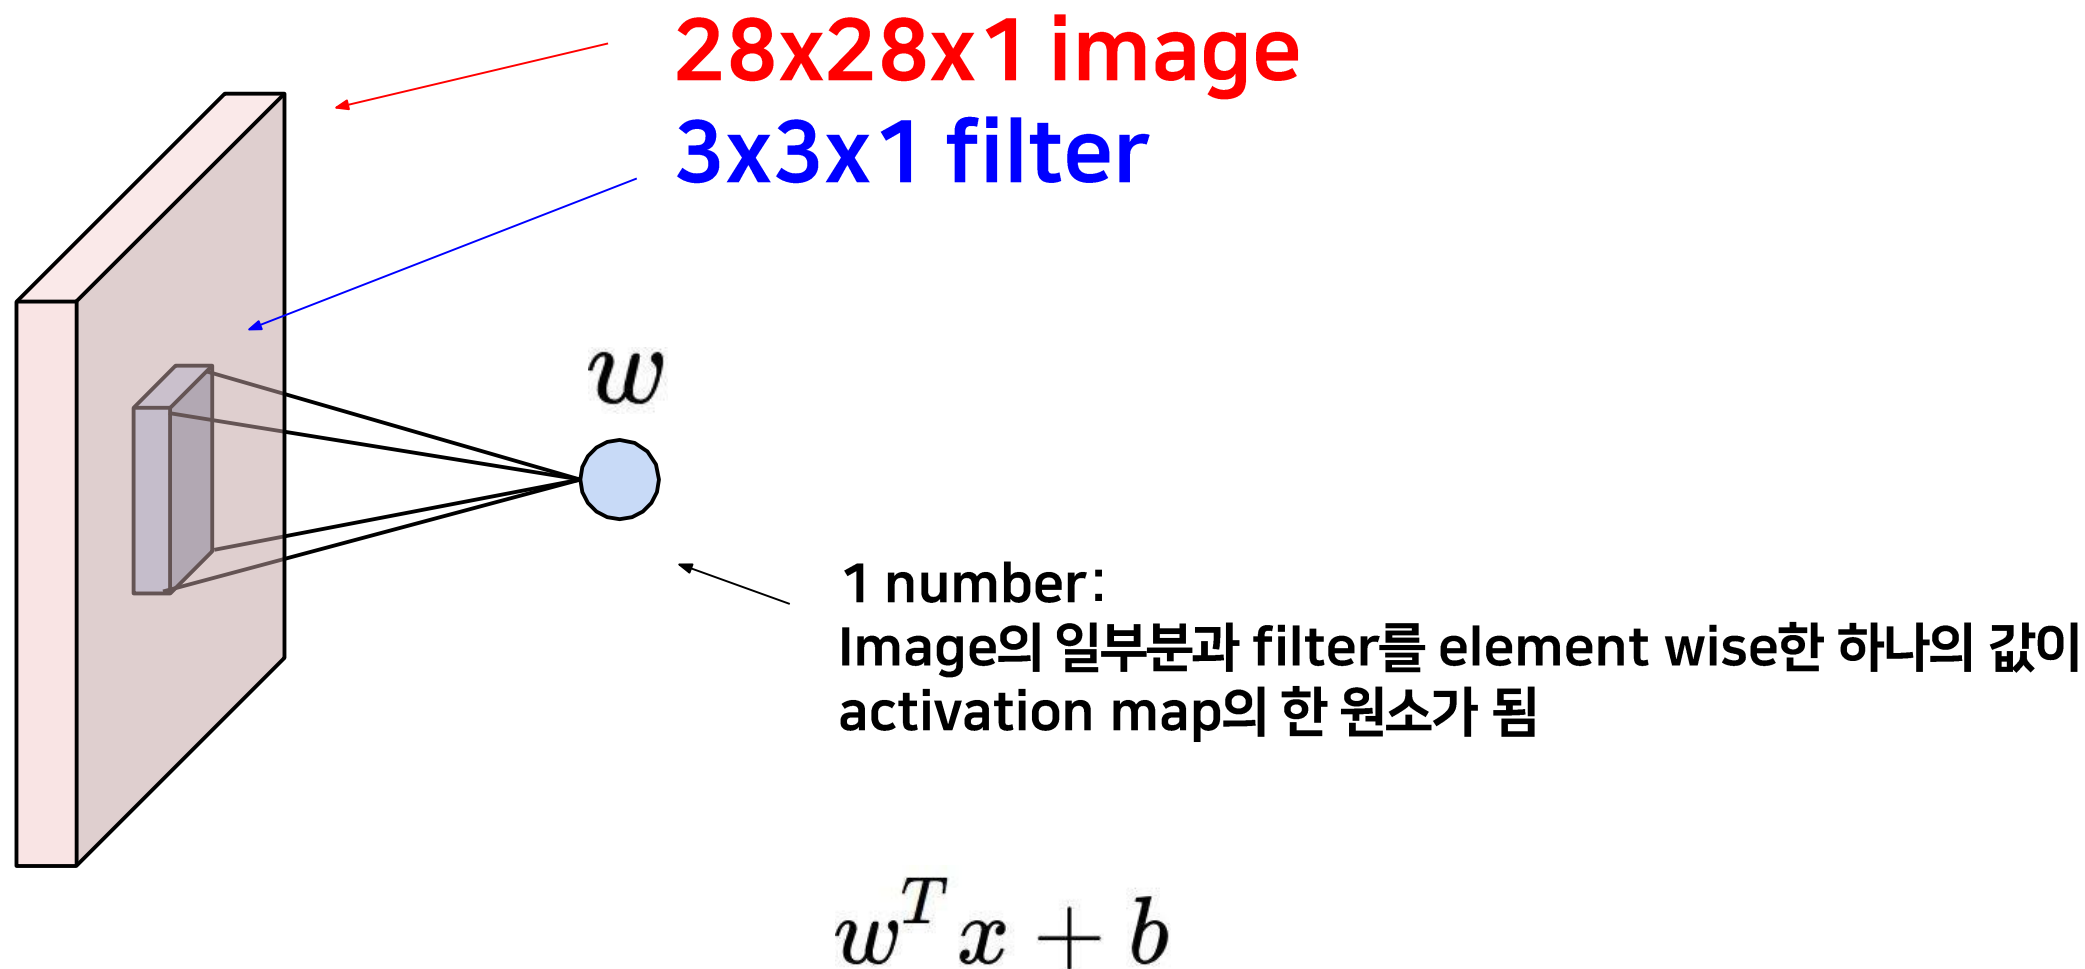
Filter는 input data와
같은 depth를 가짐

3x3x**1** filter



Convolution Layer

PIAI Research Department



Convolution Layer

PIAI Research Department

1 _{x1}	1 _{x0}	1 _{x1}	0	0
0 _{x0}	1 _{x1}	1 _{x0}	1	0
0 _{x1}	0 _{x0}	1 _{x1}	1	1
0	0	1	1	0
0	1	1	0	0


Image

4		

Convolved
Feature

Convolution Layer

PIAI Research Department



activation map


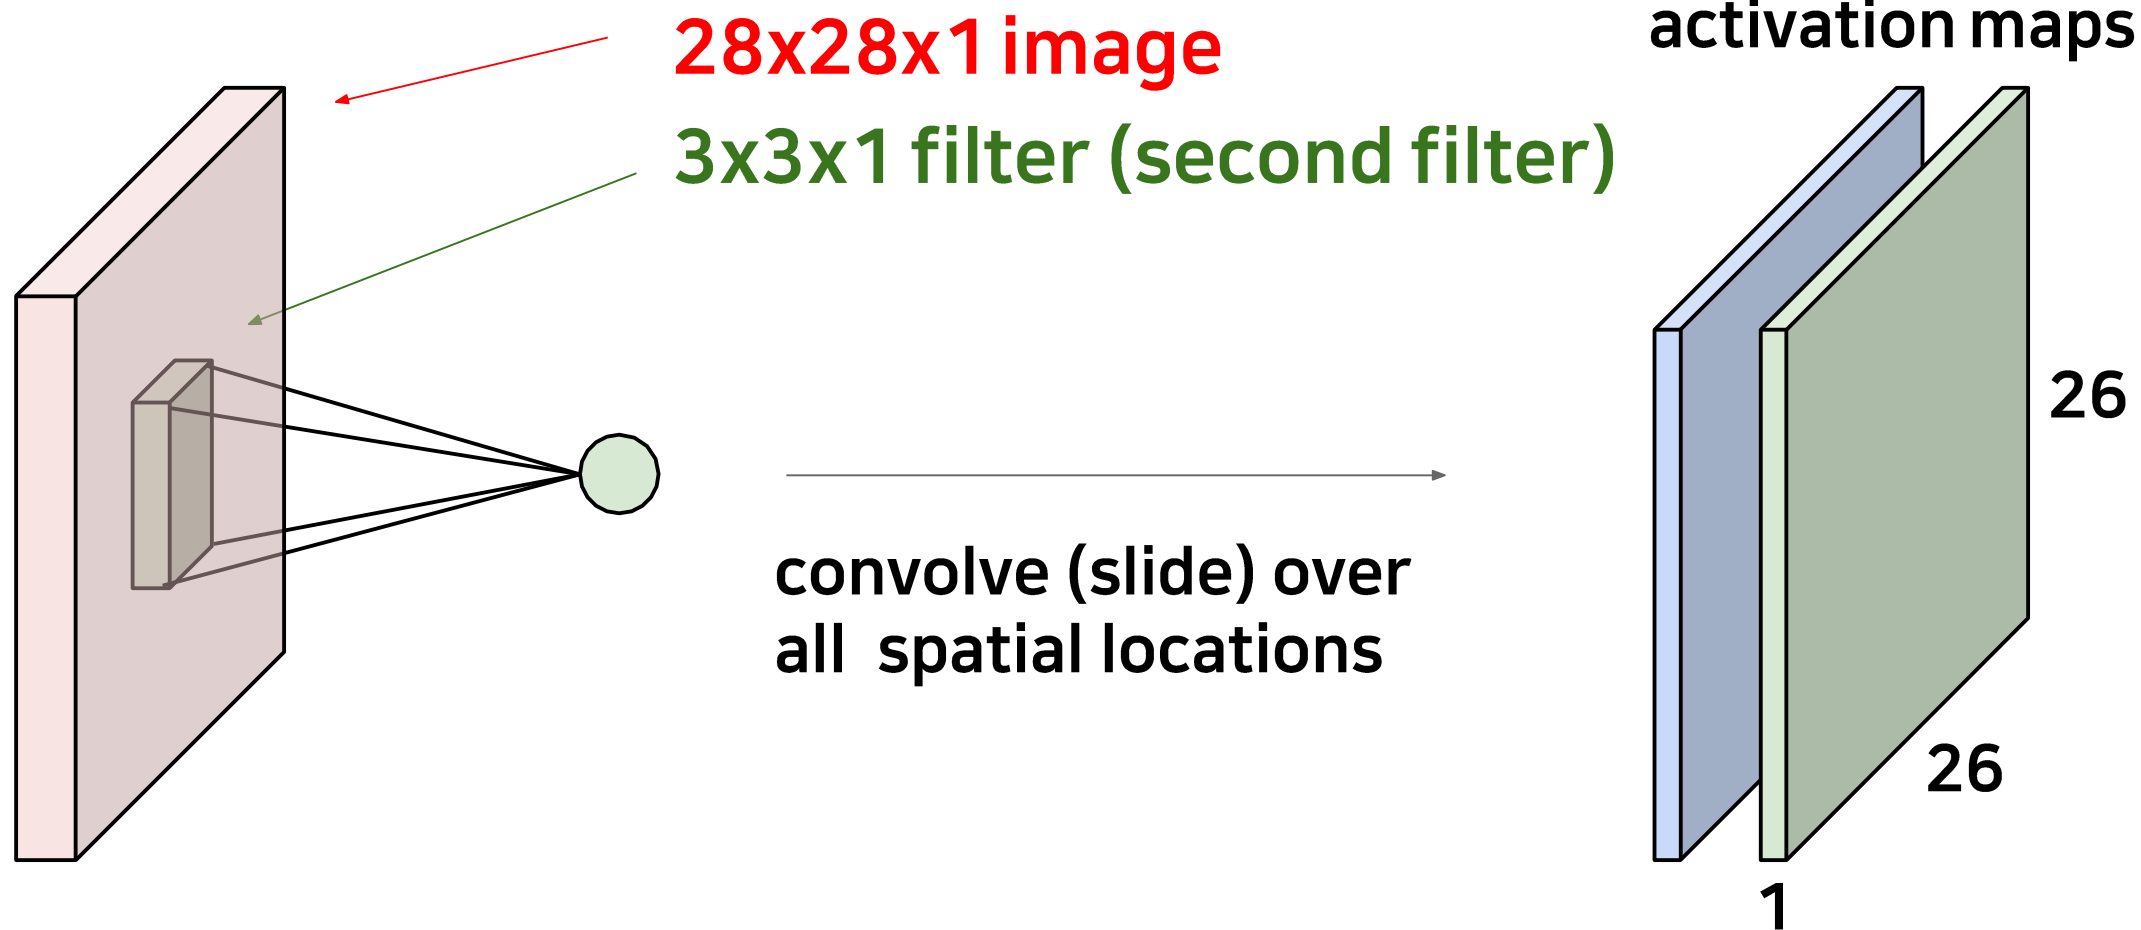



Image classification

PIAI Research Department



Convolution Layer


PIAI Research Department



26x26x6의 새로운 이미지는 다음 layer로 전달

Convolution Layer

PIAI Research Department




각각의 필터는 input image만큼의 depth를 가져야한다.

그리고 필터를 거친 activation map은 필터의 개수만큼 만들어 진다.

Padding을 적용하지 않으면 이미지의 크기가 점점 줄어들어 convolution을 진행할 수 없다. (28 -> 26 -> 22 ...)

1 × 1 Convolution Layer


PIAI Research Department



1x1 convolution layers : 이미지 크기는 유지, depth를 줄임

Pooling Layer

PIAI Research Department



Pooling layers : 이미지 크기를 줄이고, depth를 유지

Pooling Layer

PIAI Research Department

Single depth slice

x ↑

1	1	2	4
5	6	7	8
3	2	1	0
1	2	3	4

→ **y**


max pool with 2x2 filters
and stride 2

6	8
3	4

- 일반적으로 Max Pooling이나 Avg. Pooling을 사용
- Pooling 함으로써 데이터가 손실되지만 invariance를 얻음

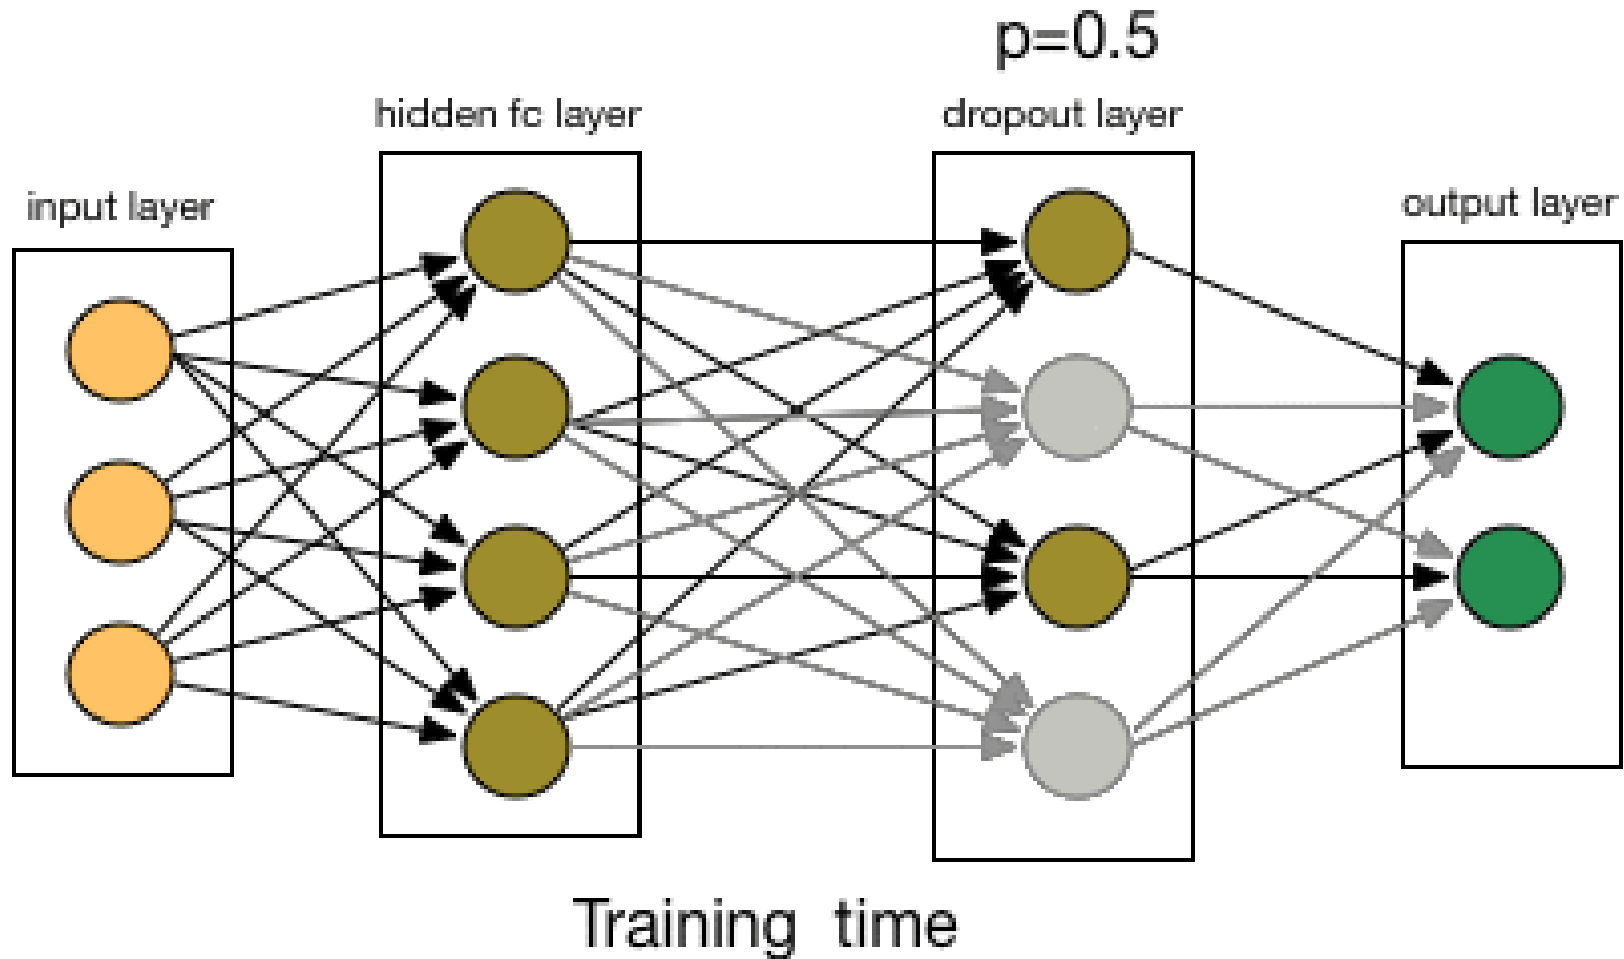
Batch Normalization

PIAI Research Department




Dropout

PIAI Research Department





Dropout


PIAI Research Department



얼굴위주



색지우고




귀 빼고



Image classification

PIAI Research Department



Code Running


(student)2_KerasFeatureExtraction.ipynb

[illegible]

CNN Feature Extraction

PIAI Research Department

- CNN – with MNIST



- 특징을 추출하기 특화
- 기존 FC와 다르게 모든 뉴런들이 연결되어 있지 않음
- MLP에 비해 학습이 효율적이고, 모델의 성능도 더 좋음
- 여러가지 학습 기법 적용 예정 (Batch Nor., EarlySt., Dropout, Check Point Save 기법 등)

CNN – 데이터 전처리

PIAI Research Department

• 데이터 전처리 – Dataset Normalization

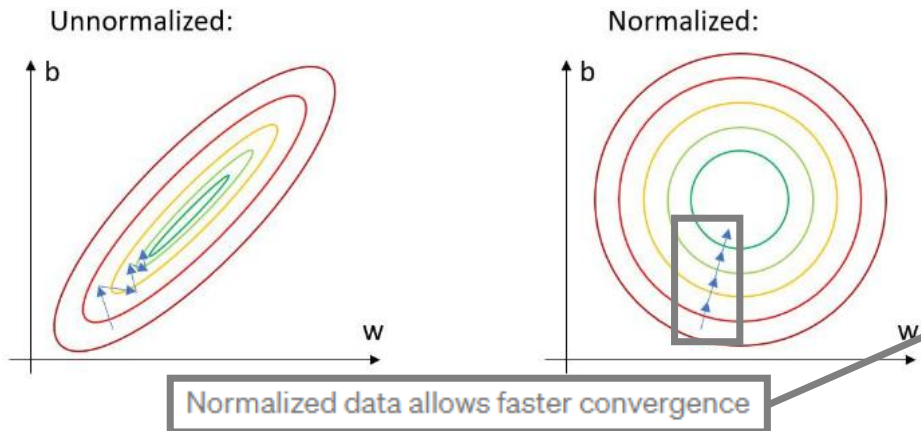
```
transforms.Compose([ToTensor(),  
                    Normalize(mean=(0.5, ), std=(0.5, ))])
```

• MNIST 데이터 정규화 작업
(임의의 평균 & 표준편차 적용)

• 데이터 Normalize를 통하여
Global Minimum으로 빠르게 수렴

• 데이터의 평균과 표준편차를 직접 계
산하여 적용 가능

(링크: <https://teddylee777.github.io/pytorch/torchvision-transform>)



데이터셋의 평균(mean)과 표준편차(std)를 계산하여 적용시

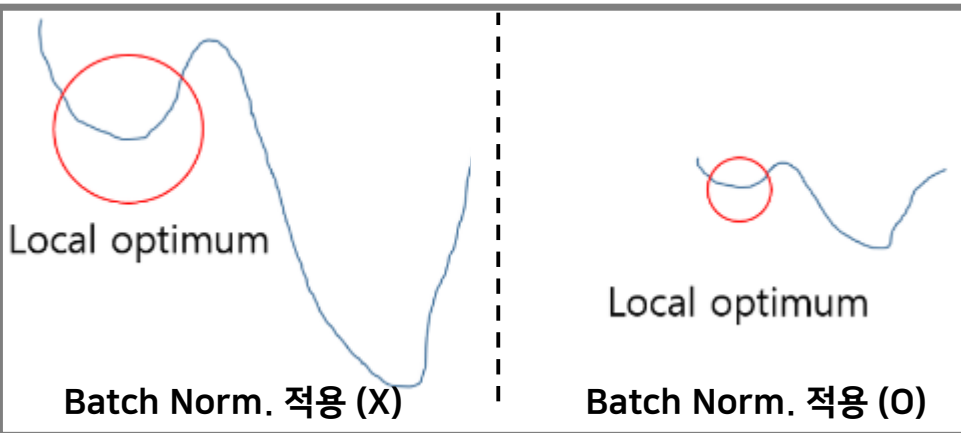

- 학습할 이미지 데이터셋이 일반적인 조도, 각도, 배경, 사물체가 아닌 경우는 직접 평균/표준편차를 계산하여 적용할 수 있습니다.

아래 함수는 이미지 데이터셋에 대하여 평균, 표준편차를 산출해 주는 함수입니다.

```
def calculate_norm(dataset):  
    # dataset의 axis=1, 2에 대한 평균 산출  
    mean_ = np.array([np.mean(x.numpy(), axis=(1, 2)) for x, _ in dataset])  
    # r, g, b 채널에 대한 각각의 평균 산출  
    mean_r = mean_[0].mean()  
    mean_g = mean_[1].mean()  
    mean_b = mean_[2].mean()
```

기능 - Batch Normalization


```
self.layer1 = torch.nn.Sequential(  
    nn.Conv2d(in_channels=1, out_channels=32, kernel_  
    nn.BatchNorm2d(32), #Batch Normalization을 수행
```



- 레이어 중간에 Batch Norm. 수행
- 이전 레이어의 파라미터 변화로 현재 레이어의 입력 분포가 바뀌는 현상 방지
- Local Minimum에 빠짐을 방지
- 수식 참조
(https://eehoeskrapp.tistory.com/430#google_vignette)

• 기능 - Dropout

```
self.layer1 = torch.nn.Sequential(  
    nn.Conv2d(in_channels=1, out_channels=32, kernel_size=3, st  
    nn.BatchNorm2d(32),  
    nn.ReLU(),  
    nn.Dropout(0.4),  
    nn.MaxPool2d(kernel_size = 2, stride = 2),  
)
```



- Dropout 기법을 사용하여 과적합을 방지
- 랜덤한 확률로 Layer 내에 있는 뉴런들을 제거 후 학습하는 기법
- 매 학습마다 새롭게 제거된 뉴런들의 조합으로 인하여 앙상블 러닝 효과 발생
- 일반적으로 0 ~ 0.5 사이로 사용

기능 - Early Stopping 기법

```
class EarlyStopping:
    """주어진 patience 이후로 validation loss가 개선되지 않으면 학습을 조기 중지"""
    def __init__(self, patience=7, verbose=False, delta=0, path='checkpoint.pt'):
        self.patience = patience
        self.verbose = verbose
    # Training Iteration
    while epoch_not_finished():
        start_time = time.time()
        tloss, tacc = epoch(train_loader_es)
        end_time = time.time()
        time_taken = end_time - start_time
        record_train_log(tloss, tacc, time_taken)
        with torch.no_grad():
            vloss, vacc = epoch(valid_loader_es)
            record_valid_log(vloss, vacc)
        print_log()

        # early_stopping은 validation loss가 감소하였는지 확인이 필요하며,
        # 만약 감소하였을 경우 현재 모델을 checkpoint로 만든다.
        early_stopping(vloss, net)
        if early_stopping.early_stop:
            print("Early stopping")
            break
```

```
EarlyStopping counter: 10 out of 10
Early stopping
```

Training completed!


```
===== Test Result =====
Test accuracy = 0.8904272151898734
Test loss = 0.4271463234496268
```

- 학습중 Over Fitting 판단시, 중간에 학습을 종료하는 기법
- [Patience]
Validation Loss에 개선이 없으면 몇 번 기다렸다 학습을 중지 할지
- 학습 알고리즘에 Early Stopping 모듈을 추가하여 Over Fitting 감지 시, while문에서 break
- Early Stopping 작동 확인

• 기능 - Check Point Save 기법

```
def __call__(self, val_loss, model):  
    score = -val_loss  
  
    if self.best_score is None:  
        self.best_score = score  
        self.save_checkpoint(val_loss, model)  
  
def save_checkpoint(self, val_loss, model):  
    # validation loss가 감소하면 모델을 저장한다.  
    if self.verbose:  
        print('Validation loss decreased ({:5} --> {:5}). Saving  
        torch.save(model.state_dict(), self.path)  
        self.val_loss_min = val_loss
```

- 학습 중 모델이 최고 점수를 기록하는 순간을 지속적으로 Epoch마다 저장
- EarlyStopping 이랑 비슷한 목적
- 학습 결과 Overfitting이 되었다고 하더라도, Best Model 보관 가능



CNN - 모델 설계

PIAI Research Department

가치창출대학

POSTECH

POHANG UNIVERSITY OF SCIENCE AND TECHNOLOGY

• CNN(Convolutional Neural Network) 모델 설계

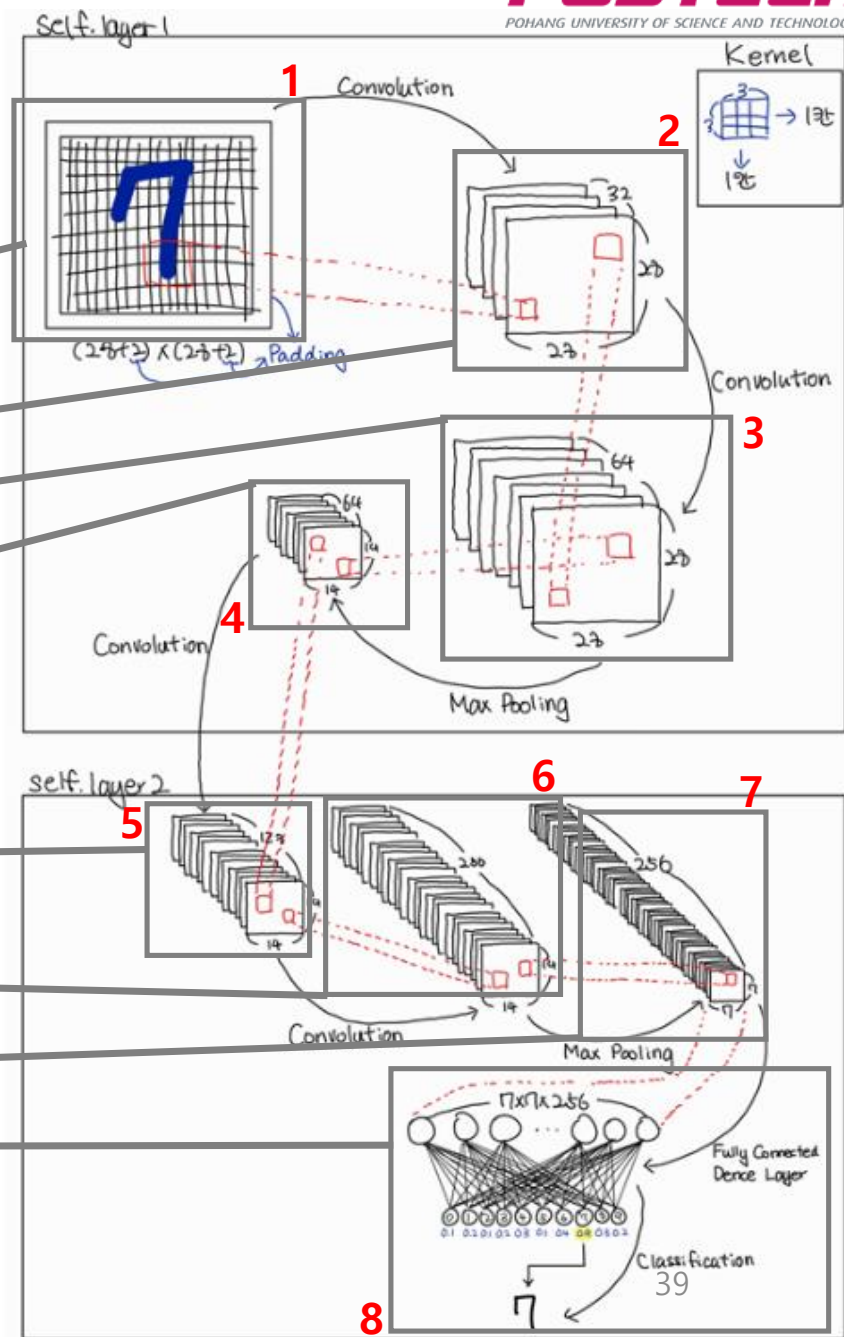
```
class CNN_model(nn.Module):
    def __init__(self):
        super(CNN_model, self).__init__()

        # 1번 레이어 생성
        self.layer1 = torch.nn.Sequential(
            nn.Conv2d(in_channels=1, out_channels=32, kernel_size=3, stride=1, padding=1),
            nn.Conv2d(in_channels=32, out_channels=64, kernel_size=3, stride=1, padding=1),
            nn.BatchNorm2d(64),
            nn.ReLU(),
            nn.Dropout(0.1),
            nn.MaxPool2d(kernel_size=2, stride=2))

        # 2번 레이어 생성
        self.layer2 = torch.nn.Sequential(
            nn.Conv2d(in_channels=64, out_channels=128, kernel_size=3, stride=1, padding=1),
            nn.Conv2d(in_channels=128, out_channels=256, kernel_size=3, stride=1, padding=1),
            nn.BatchNorm2d(256),
            nn.ReLU(),
            nn.MaxPool2d(kernel_size=2, stride=2))

        # 마지막 0 ~ 9 classification을 위한 fully connected layer 생성
        self.fcl = nn.Linear(7 * 7 * 256, 10, bias = True)

        # 가중치 초기화
        nn.init.xavier_uniform_(self.fcl.weight)
```



CNN - 모델 설계

PIAI Research Department

설계된 CNN 모델의 구조 확인

```
43 # Model structure check
44 Summary(CNN_model().to(device) (1, 28, 28))
```


Layer (type)	Output Shape	Param #
Conv2d-1	[-1, 32, 28, 28]	320
Conv2d-2	[-1, 64, 28, 28]	18,496
BatchNorm2d-3	[-1, 64, 28, 28]	128
ReLU-4	[-1, 64, 28, 28]	0
Dropout-5	[-1, 64, 28, 28]	0
MaxPool2d-6	[-1, 64, 14, 14]	0
Conv2d-7	[-1, 128, 14, 14]	73,856
Conv2d-8	[-1, 256, 14, 14]	295,168
BatchNorm2d-9	[-1, 256, 14, 14]	512
ReLU-10	[-1, 256, 14, 14]	0
MaxPool2d-11	[-1, 256, 7, 7]	0
Linear-12	[-1, 10]	125,450

Total params: 513,930
Trainable params: 513,930
Non-trainable params: 0

Input size (MB): 0.00
Forward/backward pass size (MB): 3.25
Params size (MB): 1.96
Estimated Total Size (MB): 5.22

- Summary 기능으로 설계된 모델의 구조 확인
- 입력 데이터 사이즈 확인 (1, 28, 28)

1: Gray Scale (1 channel 이미지)
28 * 28: 사진의 화소



CNN - 모델 설계

PIAI Research Department

• CNN 모델 학습 알고리즘

```
# 학습 알고리즘
def epoch(data_loader, mode = 'train'):
    global epoch_cnt

    # 사용되는 변수 초기화
    iter_loss, iter_acc, last_grad_performed, last_out, last_label = [],

    for _data, _label in data_loader:
        data, label = _data.to(device), _label.to(device)

        # 1. Feed-forward
        if mode == 'train':
            net.train()
        else:
            net.eval()
        result, _ = net(data)
        _, out = torch.max(result, 1)
```


```
# 5. 컨퓨전 매트릭스 출력을 위해 기록
last_out = out.cpu().detach()
last_label = _label
```

- Day1 알고리즘에서 **2개** 기능 추가
- 1) Train/Valid 모드에 따라 다르게 동작

- net.train() :
dropout, batch nor. -> 사용

- net.eval() :
dropout, batch nor. -> 미사용

- 2) Confusion Matrix 기록 로직 추가



CNN – Verbose Setting(Graph)

PIAI Research Department


• Verbose – 실시간 학습 추이 그래프 출력

```
# 학습 추이 그래프 출력
hist_fig, loss_axis = plt.subplots(figsize=(10, 3), dpi=99) # 그래프 사이즈 설정
hist_fig.patch.set_facecolor('white') # 그래프 배경색 설정

# Loss Line 구성
loss_t_line = plt.plot(iter_log, tloss_log, label='Train Loss', color='red', marker='o')
loss_v_line = plt.plot(iter_log, vloss_log, label='Valid Loss', color='blue', marker='s')
loss_axis.set_xlabel('epoch')
loss_axis.set_ylabel('loss')

# Acc. Line 구성
acc_axis = loss_axis.twinx()
acc_t_line = acc_axis.plot(iter_log, tacc_log, label='Train Acc.', color='red', marker='+')
acc_v_line = acc_axis.plot(iter_log, vacc_log, label='Valid Acc.', color='blue', marker='x')
acc_axis.set_ylabel('accuracy')

# 그래프 출력
hist_lines = loss_t_line + loss_v_line
loss_axis.legend(hist_lines, [l.get_label() for l in hist_lines])
loss_axis.grid() # 격자 설정
plt.title('Learning history until epoch 43')
plt.draw()
```




- 학습 추이를 그래프를 통하여 실시간으로 모니터링
- Train과 Validation에 대하여 Loss와 Acc.를 실시간으로 시각화

CNN 모델 학습

```

1 # Training Initialization
2 init_model()
3 init_epoch()
4 init_log()
5 plt.rc('font', size = 10)
6
7 best_test_acc, best_epoch = 0, 0
8 # Training Iteration
9 while epoch_not_finished():
10     start_time = time.time()
11     tloss, tacc = epoch(train_loader)
12     end_time = time.time()
13     time_taken = end_time - start_time
14     record_train_loss(tloss)
15     with torch.no_grad():
16         vloss, vacc = epoch(valid_loader)
17     record_val_loss(vloss)
18     print_log()
19
20     with torch.no_grad():
21         net.eval()
22         _, test_acc = test_model(net, test_loader)

```




- CNN 모델 학습
- 실시간 그래프로 학습 추이 확인
- 모델의 정확도 확인

Test Acc.: 0.9898
Test Loss: 0.0321

- Confusion Matrix

```
1 # Confusion matrix
2 our_cmatrix = confusion_matrix(test_label, test_out)
3 plt.figure(figsize=(8, 6), dpi=99)
4 sns.heatmap(our_cmatrix, annot=True, fmt='g', cmap='YlGn').set(xlabel='Predicted', ylabel='Truth')
5 plt.title('Confusion Matrix')
6 plt.show()
```



- 혼동 행렬을 통하여 모델이 예측하는 10개의 Class에 대한 성능을 한눈에 가시화
- 모든 Class에 대하여 모델이 분류한 결과 확인




CNN - 결과 분석

PIAI Research Department

• 모델의 오 분류 사례 분석

```
# 예측 결과 1, 2, 3순위를 만드는 과정
max_pred = max(pred_info)
second_pred = pred_info[1]
third_pred = pred_info[2]
pred_label = pred_info.index(max_pred)
second_label = pred_info.index(second_pred)
third_label = pred_info.index(third_pred)
```

```
# 정답과 예측 결과가 다른 경우(모델이 잘못 분류한 경우)
if gt_label != pred_label:
    # plt로 4개를 한번에 출력하기 때문에 4번동안 리스트에 누적시킨다
    show_cnt += 1
    wrong_pic, _ = test_data[cnt]
    plt_pic_list.append(wrong_pic)
    gt_label_list.append(gt_label)
    pred_label_list.append(pred_label)
    second_pred_label_list.append(second_label)
    third_pred_label_list.append(third_label)
    plt_cnt += 1
```



- 학습된 모델이 잘못 분류한 케이스 분석
- 모델의 Prediction 결과가 Ground Truth랑 다른 경우를 예측 확률 순위로 1, 2, 3위 출력
(정답지가 4인 사진을 6로 잘못 예측했으며, 두번째 세번째 후보는 4과 2)
- 모델이 잘못했는지, 데이터가 잘못되었는지를 판단

Code Running

(student)2. Pytorch CNN – Feature Extraction.ipynb